

1 Đề tài 2: Mức lương ở các vị trí việc làm trong lĩnh vực khoa học dữ liệu

1.1 Giới thiệu bộ dữ liệu và mục tiêu phân tích

1.1.1 Giới thiệu bộ dữ liệu

Bộ dữ liệu **Data Science Job Salaries** (Kaggle, 2022) ghi nhận mức lương của các vị trí việc làm trong lĩnh vực khoa học dữ liệu trên phạm vi toàn cầu, giai đoạn 2020–2022. Mỗi quan sát là một hợp đồng lao động, gắn với cấp độ kinh nghiệm (`experience_level`), hình thức làm việc (`employment_type`), chức danh cụ thể (`job_title`), mức lương gốc và mức lương đã quy đổi sang USD (`salary_in_usd`), quốc gia cư trú của người lao động và quốc gia đặt trụ sở công ty, tỷ lệ làm việc từ xa (`remote_ratio`), và quy mô công ty (`company_size`). Biến mục tiêu của toàn bộ phân tích là `salary_in_usd` — mức lương quy đổi sang USD, được chọn thay vì lương gốc (`salary`) vì đảm bảo tính so sánh được giữa các quốc gia và loại tiền tệ khác nhau.

Bộ dữ liệu gồm 607 quan sát và 11 biến gốc; bảng mô tả chi tiết từng biến được trình bày ở mục “Khám phá ban đầu” ngay dưới đây.

1.1.2 Mục tiêu phân tích

Phân tích khám phá dữ liệu (EDA) và xây dựng các mô hình dự đoán, đánh giá những yếu tố ảnh hưởng đến mức lương ở các vị trí việc làm trong lĩnh vực khoa học dữ liệu trên phạm vi toàn cầu.

Cụ thể, phân tích xác định chiều và mức độ ảnh hưởng của kinh nghiệm, nhóm nghề nghiệp, quy mô công ty, hình thức làm việc, mức độ làm việc từ xa và khu vực địa lý đến `salary_in_usd`; so sánh mức lương giữa các nhóm bằng kiểm định thống kê phù hợp; và xem xét xu hướng lương qua 2020–2022 sau khi kiểm soát khác biệt cơ cấu mẫu giữa các năm. Trên cơ sở đó, nhiều mô hình hồi quy được xây dựng và so sánh bằng RMSE, MAE, R^2 để chọn mô hình dự đoán tốt nhất, làm căn cứ diễn giải các biến quan trọng và đề xuất hướng cải thiện.

1.2 Tiền xử lý dữ liệu

1.2.1 Khám phá ban đầu

```
## Số quan sát: 607
```

```
## Số biến      : 11
```

```
## 'data.frame':    607 obs. of  11 variables:
```

```
## $ work_year      : int  2020 2020 2020 2020 2020 2020 2020 2020 2020 2020 2020 ...
```

```
## $ experience_level : chr  "MI" "SE" "SE" "MI" ...
```

```
## $ employment_type  : chr  "FT" "FT" "FT" "FT" ...
```

```
## $ job_title        : chr  "Data Scientist" "Machine Learning Scientist" "Big Data Engineer"
```

```
## $ salary           : int  70000 260000 85000 20000 150000 72000 190000 11000000 135000 12500
```

```
## $ salary_currency  : chr  "EUR" "USD" "GBP" "USD" ...
```

```
## $ salary_in_usd    : int  79833 260000 109024 20000 150000 72000 190000 35735 135000 125000
```

```
## $ employee_residence: chr  "DE" "JP" "GB" "HN" ...
```

```
## $ remote_ratio     : int  0 0 50 0 50 100 100 50 100 50 ...
```

```
## $ company_location : chr  "DE" "JP" "GB" "HN" ...
```

```
## $ company_size     : chr  "L" "S" "M" "S" ...
```

Table 1: 8 quan sát đầu tiên của bộ dữ liệu gốc

	work_year	experience_level	employment_type	job_title	salary	salary_currency	salary_in_usd	employee_residence	remote_ratio	company_location	company_size
0	2020	MI	FT	Data Scientist	70,000	EUR	79,833	DE	0	DE	L
1	2020	SE	FT	Machine Learning Scientist	260,000	USD	260,000	JP	0	JP	S
2	2020	SE	FT	Big Data Engineer	85,000	GBP	109,024	GB	50	GB	M
3	2020	MI	FT	Product Data Analyst	20,000	USD	20,000	HN	0	HN	S
4	2020	SE	FT	Machine Learning Engineer	150,000	USD	150,000	US	50	US	L
5	2020	EN	FT	Data Analyst	72,000	USD	72,000	US	100	US	L
6	2020	SE	FT	Lead Data Scientist	190,000	USD	190,000	US	100	US	S
7	2020	MI	FT	Data Scientist	11,000,000	HUF	35,735	HU	50	HU	L

Bộ dữ liệu **Data Science Job Salaries** (Kaggle, 2022) gồm 607 quan sát và 11 biến, ghi nhận thông tin về mức lương của các vị trí trong ngành Data Science từ năm 2020 đến 2022. Biến mục tiêu là `salary_in_usd` — mức lương quy đổi ra đô-la Mỹ, đảm bảo tính so sánh được giữa các quốc gia và loại tiền tệ khác nhau.

Table 2: Mô tả 11 biến trong bộ dữ liệu gốc

Biến	Kiểu	Mô_tả
<code>work_year</code>	integer	Năm ghi nhận dữ liệu lương
<code>experience_level</code>	character	Cấp độ kinh nghiệm (EN/MI/SE/EX)
<code>employment_type</code>	character	Loại hợp đồng (FT/PT/CT/FL)
<code>job_title</code>	character	Chức danh công việc
<code>salary</code>	integer	Lương trong đồng tiền địa phương
<code>salary_currency</code>	character	Đơn vị tiền tệ
<code>salary_in_usd</code>	integer	Lương quy đổi sang USD — biến mục tiêu
<code>employee_residence</code>	character	Quốc gia cư trú của nhân viên
<code>remote_ratio</code>	integer	Tỷ lệ làm việc từ xa (0/50/100)
<code>company_location</code>	character	Quốc gia đặt trụ sở công ty
<code>company_size</code>	character	Quy mô công ty (S/M/L)

Bộ dữ liệu gồm 1 biến phụ thuộc `salary_in_usd` và 10 biến độc lập, trong đó có 2 biến là định lượng `work_year`, `remote_ratio` nhưng rời rạc và hữu hạn, 8 biến là biến định tính.

1.2.2 Kiểm tra dữ liệu thiếu

Table 3: Tổng hợp dữ liệu thiếu theo từng biến

Biến	Số_NA	Tỷ_lệ_NA_pct
work_year	0	0
experience_level	0	0
employment_type	0	0
job_title	0	0
salary	0	0
salary_currency	0	0
salary_in_usd	0	0
employee_residence	0	0
remote_ratio	0	0
company_location	0	0
company_size	0	0

Toàn bộ 11 biến đều không có giá trị thiếu — tổng cộng 0 NA.

1.2.3 Kiểm tra dữ liệu trùng lặp

Table 4: Kiểm tra dữ liệu trùng lặp

Chỉ.tiêu	Kết.quả
Số hàng trùng lặp hoàn toàn	42.00
Tỷ lệ trùng lặp (%)	6.92

Table 5: Các hàng trùng lặp — hiển thị 10/71 hàng liên quan (mỗi nhóm trùng lặp gồm cả bản gốc lẫn bản sao)

work_year	experience_level	employment_type	job_title	salary	salary_currency	salary_in_usd	employee_residence	remote_ratio	company_location	company_size
2021	MI	FT	Data Engineer	200000	USD	200000	US	100	US	L
2021	MI	FT	Data Engineer	200000	USD	200000	US	100	US	L
2021	MI	FT	Data Scientist	76760	EUR	90734	DE	50	DE	L
2021	MI	FT	Data Scientist	76760	EUR	90734	DE	50	DE	L
2022	MI	FT	Data Analyst	58000	USD	58000	US	0	US	S
2022	MI	FT	Data Analyst	58000	USD	58000	US	0	US	S
2022	MI	FT	Data Engineer	60000	GBP	78526	GB	100	GB	M
2022	MI	FT	Data Engineer	60000	GBP	78526	GB	100	GB	M
2022	MI	FT	ETL Developer	50000	EUR	54957	GR	0	GR	M
2022	MI	FT	ETL Developer	50000	EUR	54957	GR	0	GR	M

Bộ dữ liệu có 42 hàng trùng lặp hoàn toàn — loại bỏ, còn lại 565 quan sát. Lưu ý: trong dữ liệu khảo sát lương, hai nhân viên khác nhau hoàn toàn có thể có cùng tổ hợp giá trị (cùng năm, cùng chức danh, cùng mức lương) — đây không phải lỗi nhập liệu. Tuy nhiên, hàng trùng lặp *hoàn toàn* trên tất cả 11 cột nhiều khả năng là dữ liệu nhập đôi, nên được loại bỏ.

1.2.4 Loại bỏ biến dư thừa

Qua quan sát ban đầu, nhận thấy có 2 biến có vẻ sẽ không mang nhiều ý nghĩa cho mô hình là 2 biến `salary` (lương địa phương) và `salary_currency` (đơn vị tiền tệ tính lương), vì biến `salary` thì có vẻ đã được quy đổi qua biến phụ thuộc là biến `salary_in_usd` còn biến `salary_currency` thì được kết hợp với biến `salary` để quy đổi qua tiền lương theo USD, và biến này nếu được đặc trưng cho đất nước mà người khảo sát làm việc thì cũng có thể đã được thể hiện qua 2 biến `company_location` hoặc `employee_residence`.

Theo mô tả dữ liệu, `salary_in_usd` là mức lương quy đổi sang USD (tính theo tỷ giá hối đoái chia cho tỷ giá USD trung bình của năm tương ứng, dựa trên dữ liệu từ `fxdata.foorilla.com`). Tuy nhiên trang `fxdata.foorilla.com` đã không còn tồn tại, và để kiểm chứng giả định rằng biến `salary` đã quy đổi qua USD 1 cách tuyến tính theo tỷ giá đồng nhất, nhóm tính toán tỷ giá bằng cách chia lương đã quy đổi sang USD cho lương địa phương và so sánh tỷ giá này giữa các đơn vị tiền tệ và năm. Kết quả như bảng dưới đây:

Table 6: Tỷ giá ngầm định (`salary_in_usd / salary`) theo đơn vị tiền tệ và năm

Tiền tệ	Năm	Min	Max	Mean	Số tỷ giá khác nhau
AUD	2022	0.72252	0.72252	0.72252	1
BRL	2021	0.18536	0.18536	0.18536	1
CAD	2020	0.74589	0.74589	0.74589	1
CAD	2021	0.79762	0.79763	0.79762	1
CAD	2022	0.78791	0.78792	0.78791	1
CHF	2022	1.06388	1.06388	1.06388	1
CLP	2021	0.00132	0.00132	0.00132	1
CNY	2020	0.14492	0.14492	0.14492	1
CNY	2022	0.15515	0.15515	0.15515	1
DKK	2020	0.15299	0.15299	0.15299	1
DKK	2021	0.15894	0.15894	0.15894	1
EUR	2020	1.14043	1.14047	1.14046	2
EUR	2021	1.18196	1.18206	1.18205	2
EUR	2022	1.09913	1.09915	1.09914	2
GBP	2020	1.28263	1.28264	1.28263	1
GBP	2021	1.37545	1.37547	1.37546	1
GBP	2022	1.30876	1.30878	1.30877	1
HUF	2020	0.00325	0.00325	0.00325	1
HUF	2021	0.00330	0.00330	0.00330	1
INR	2020	0.01349	0.01349	0.01349	1
INR	2021	0.01352	0.01352	0.01352	1
INR	2022	0.01317	0.01317	0.01317	1
JPY	2020	0.00937	0.00937	0.00937	1
JPY	2021	0.00910	0.00910	0.00910	1
MXN	2020	0.04654	0.04654	0.04654	1
MXN	2021	0.04929	0.04929	0.04929	1
PLN	2021	0.25887	0.25887	0.25887	1
PLN	2022	0.23727	0.23727	0.23727	1
SGD	2021	0.74412	0.74412	0.74412	1
TRY	2021	0.11206	0.11206	0.11206	1
USD	2020	1.00000	1.00000	1.00000	1

Table 6: Tỷ giá ngầm định ($\text{salary_in_usd} / \text{salary}$) theo đơn vị tiền tệ và năm (*continued*)

Tiền tệ	Năm	Min	Max	Mean	Số tỷ giá khác nhau
USD	2021	1.00000	1.00000	1.00000	1
USD	2022	1.00000	1.00000	1.00000	1

Theo bảng trên, nếu lấy đến chữ số thập phân thứ tư, đa số các tỷ giá đều bằng nhau ở từng năm quan sát với từng đơn vị tiền tệ, có đồng EUR khi quan sát có sự sai số ở số thập phân thứ 4. Điều này có thể lý giải cho người thu thập dữ liệu, khi họ nhân tỷ giá đã làm tròn dẫn đến khi chia sẽ có sai số như vậy. Vì sai số là nhỏ nên nhóm chấp nhận kết quả salary_in_usd đã được tính và bỏ biến salary vì đã được quy đổi qua biến phụ thuộc.

Hai biến salary (lương địa phương) và salary_currency (đơn vị tiền tệ) bị loại vì chúng phụ thuộc hoàn toàn vào salary_in_usd — mọi thông tin về quy mô lương đã được quy đổi và gộp vào biến mục tiêu. Giữ lại biến tiền tệ chỉ đưa thêm ~17 dummy tiền tệ vào mô hình mà không đóng góp thông tin dự báo độc lập (Sheather 2009, §2.1).

1.2.5 Xử lý các biến định tính

1.2.5.1 Xử lý các nhóm chức danh Xét tới các biến nhóm định tính có ít mức (tần suất từng mức):

Table 7: Tần suất các biến phân loại ít mức — trước khi mã hoá lại reference level

Biến	Mức	Số lượng
experience_level	EN	88
	EX	26
	MI	208
	SE	243
employment_type	CT	5
	FL	4
	FT	546
	PT	10
company_size	L	193
	M	290
	S	82
remote_ratio	0	121
	50	98
	100	346
work_year	2020	72
	2021	215
	2022	278

Ba biến định tính còn lại — `job_title`, `company_location`, `employee_residence` — có số lượng mức rất lớn (trên 50 giá trị khác nhau mỗi biến). Bảng dưới đây trình bày tần suất từng mức, sắp xếp giảm dần theo số lượng quan sát:

Table 8: Tần suất `job_title` gốc (50 chức danh khác nhau) — trước khi gom nhóm thành `job_category`

Chức danh	Số lượng
Data Scientist	130
Data Engineer	121
Data Analyst	82
Machine Learning Engineer	39
Research Scientist	16
Data Science Manager	12
Data Architect	11
Big Data Engineer	8
Machine Learning Scientist	8
AI Scientist	7
Data Analytics Manager	7
Data Science Consultant	7
Director of Data Science	7
Principal Data Scientist	7
BI Data Analyst	6
Computer Vision Engineer	6
Lead Data Engineer	6
ML Engineer	6
Applied Data Scientist	5
Business Data Analyst	5
Data Engineering Manager	5
Head of Data	5
Analytics Engineer	4
Applied Machine Learning Scientist	4
Data Analytics Engineer	4
Head of Data Science	4
Computer Vision Software Engineer	3
Data Science Engineer	3
Lead Data Analyst	3
Lead Data Scientist	3
Machine Learning Developer	3
Machine Learning Infrastructure Engineer	3
Principal Data Engineer	3
Cloud Data Engineer	2
Director of Data Engineering	2
Financial Data Analyst	2
Principal Data Analyst	2
Product Data Analyst	2
3D Computer Vision Researcher	1
Big Data Architect	1

Table 8: Tần suất job_title gốc (50 chức danh khác nhau) — trước khi gom nhóm thành job_category (*continued*)

Chức danh	Số lượng
Data Analytics Lead	1
Data Specialist	1
ETL Developer	1
Finance Data Analyst	1
Head of Machine Learning	1
Lead Machine Learning Engineer	1
Machine Learning Manager	1
Marketing Data Analyst	1
NLP Engineer	1
Staff Data Scientist	1

Table 9: Tần suất company_location gốc (50 quốc gia) — trước khi gộp thành company_region

Mã quốc gia	Số lượng
US	318
GB	46
CA	28
DE	27
IN	24
FR	15
ES	14
GR	10
JP	6
AT	4
NL	4
PL	4
PT	4
AE	3
AU	3
BR	3
DK	3
LU	3
MX	3
PK	3
TR	3
BE	2
CH	2
CN	2
CZ	2
IT	2
NG	2
RU	2

Table 9: Tần suất company_location gốc (50 quốc gia) — trước khi gộp thành company_region (*continued*)

Mã quốc gia	Số lượng
SI	2
AS	1
CL	1
CO	1
DZ	1
EE	1
HN	1
HR	1
HU	1
IE	1
IL	1
IQ	1
IR	1
KE	1
MD	1
MT	1
MY	1
NZ	1
RO	1
SG	1
UA	1
VN	1

Tương tự, tần suất mã quốc gia gốc của employee_residence trước khi gộp:

Table 10: Tần suất employee_residence gốc (57 quốc gia)



Mã quốc gia	Số lượng
US	295
GB	43
IN	30
CA	27
DE	24
FR	18
ES	15
GR	12
JP	7
BR	6
PK	6
PT	6
NL	5
IT	4
PL	4

Table 10: Tần suất employee_residence gốc (57 quốc gia) (*continued*)

Mã quốc gia	Số lượng
RU	4
AE	3
AT	3
AU	3
TR	3
VN	3
BE	2
DK	2
HU	2
MX	2
NG	2
RO	2
SG	2
SI	2
AR	1
BG	1
BO	1
CH	1
CL	1
CN	1
CO	1
CZ	1
DZ	1
EE	1
HK	1
HN	1
HR	1
IE	1
IQ	1
IR	1
JE	1
KE	1
LU	1
MD	1
MT	1
MY	1
NZ	1
PH	1
PR	1
RS	1
TN	1
UA	1

Xử lý gom nhóm các nhóm chức danh

```
##
## Data Analyst Data Engineer Data Scientist ML Engineer Other
##      120      160      195      84      6
```



Để giảm số mức của biến `job_title` (high cardinality), hơn 50 chức danh được gom về 5 nhóm chức năng: **Data Analyst** (trực quan hóa), **Data Engineer** (hạ tầng), **Data Scientist** (mô hình thống kê), **ML Engineer** (triển khai AI/ML), và **Other** (các chức danh còn lại, gồm cả vị trí quản lý/lãnh đạo không khớp từ khóa chức năng nào). Cách gom này cân bằng cỡ mẫu giữa các nhóm, đảm bảo sức mạnh thống kê cho ANOVA và hồi quy ở các bước sau. **Data Scientist** và **Data Engineer** chiếm tỷ trọng lớn nhất.

Table 11: Phân phối biến seniority (dùng để đối chiếu, không đưa vào mô hình)

Seniority	Số lượng
Individual Contributor	496
Manager	25
Lead	13
Principal	12
Head	10
Director	9


Table 12: Bảng đối chiếu số lượng giữa experience_level và seniority

Experience level	Director	Head	Individual Contributor	Lead	Manager	Principal
EN	0	0	88	0	0	0
EX	6	6	10	1	1	2
MI	0	2	197	4	3	2
SE	3	2	201	8	21	8

Quy đổi bảng trên sang tỷ lệ phần trăm theo cột giúp so sánh trực tiếp cơ cấu experience_level giữa các nhóm seniority, không phụ thuộc chênh lệch cỡ mẫu giữa các cột:

Table 13: Tỷ lệ phần trăm phân bổ experience_level trong từng seniority

Experience level	Director	Head	Individual Contributor	Lead	Manager	Principal
EN	0.0	0	17.7	0.0	0	0.0
EX	66.7	60	2.0	7.7	4	16.7
MI	0.0	20	39.7	30.8	12	16.7
SE	33.3	20	40.5	61.5	84	66.7



Biến phái sinh seniority bị loại khỏi mô hình vì trùng lặp thông tin lớn với experience_level — vốn đã phân loại cấp bậc chi tiết hơn — nên giữ cả hai sẽ gây đa cộng tuyến mà không thêm thông tin. Tín hiệu “quản lý/lãnh đạo” cũng không tách riêng trong job_category, mà gộp vào nhóm chức năng gần nhất hoặc “Other” — một giới hạn được ghi nhận ở phần hạn chế mô hình.

1.2.5.2 Xử lý biến location Trước tiên kiểm tra mức độ trùng lặp giữa company_location và employee_residence:

Tỷ lệ trùng khớp 91% xác nhận hai biến mang thông tin gần như trùng lặp hoàn toàn — đưa cả hai vào mô hình sẽ gây đa cộng tuyến nghiêm trọng. Nhóm áp dụng chiến lược hai bước:

1. **Gom nhóm company_location → company_region:** trước tiên phân loại chi tiết theo chuẩn **M49 Geoscheme** của Liên Hợp Quốc (UNSD, 2023) để kiểm tra đầy đủ 50+ country code.
2. **Tạo biến nhị phân cross_border = 1** khi nhân viên sống khác quốc gia với công ty — thể hiện thông tin duy nhất của employee_residence mà không trùng lặp với company_region.

Table 14: Phân phối company_region_detail — 6 vùng theo UN M49 Geoscheme

Vùng (M49)	Số lượng
Northern_America	346
Europe	157
Asia	44
Latin_America	9
Oceania	5
Africa	4

4/6 vùng M49 có cỡ mẫu quá nhỏ ($n \leq 8$), tập trung lệch về Bắc Mỹ và Châu Âu. Để tránh sai số chuẩn bị phình to làm sai lệch kiểm định, các vùng thiếu số được gộp thành ‘Rest of World’, tạo 3 nhóm đủ cỡ mẫu cho hồi quy và ANOVA ở bước sau.

Table 15: Phân phối company_region sau khi gộp — 3 nhóm dùng cho mô hình (cross_border chiếm 9 phần trăm quan sát)

Khu vực (3 nhóm)	Số lượng
Northern_America	346
Europe	157
Rest_of_World	62

Sau khi gộp, company_region còn 3 nhóm: **Northern_America** (346 quan sát), **Europe** (157 quan sát), và **Rest_of_World** — gộp từ Asia, Latin America, Oceania, Africa và Other (62 quan sát). company_region_detail (6 vùng M49) chỉ giữ lại để tra cứu/kiểm tra, không đưa vào tập dữ liệu mô hình.

employee_residence bị loại vì thông tin duy nhất của nó đã được nắm bắt qua cross_border. company_location được thay thế bằng company_region — phân loại chi tiết theo 6 vùng M49 (UNSD 2023) rồi gộp tiếp thành **3 nhóm** (Northern_America, Europe, Rest_of_World) do 4/6 vùng M49 gốc có cỡ mẫu quá nhỏ (2–44 quan sát) để ước lượng hệ số dummy đáng tin cậy. Job_title được gom nhóm thành job_category. Cách này giảm số lượng dummy từ 50+ xuống còn 2 + 1, đồng thời loại bỏ đa cộng tuyến giữa hai biến location.

1.2.5.3 Mã hoá biến phân loại Phân phối của 5 biến phân loại ít mức không đổi so với bảng tần suất ở mục trên (việc gom nhóm job_title/company_location/employee_residence không ảnh hưởng đến các biến này); bước tiếp theo là mã hoá lại nhãn và ấn định reference level cho từng biến:

Biến trong tập dữ liệu mô hình:

```
## 'data.frame':   565 obs. of  9 variables:
## $ work_year      : int  2020 2020 2020 2020 2020 2020 2020 2020 2020 2020 ...
## $ experience_level: Factor w/ 4 levels "Entry","Mid",...: 2 3 3 2 3 1 3 2 2 3 ...
## $ employment_type: Factor w/ 4 levels "FullTime","PartTime",...: 1 1 1 1 1 1 1 1 1 1 ...
## $ salary_in_usd   : int  79833 260000 109024 20000 150000 72000 190000 35735 135000 125000 ...
## $ remote_ratio    : Factor w/ 3 levels "Onsite","Hybrid",...: 1 1 2 1 2 3 3 2 3 2 ...
## $ company_size    : Factor w/ 3 levels "Small","Medium",...: 3 1 2 1 3 3 1 3 3 1 ...
## $ job_category    : Factor w/ 5 levels "Data Analyst",...: 3 4 2 1 4 1 3 3 1 2 ...
```


```
## $ company_region : Factor w/ 3 levels "Northern_America",...: 2 3 2 3 1 1 1 2 1 3 ...
## $ cross_border   : int   0 0 0 0 0 0 0 0 0 0 ...
```

Table 16: Lựa chọn reference level cho từng biến phân loại

Biến	Reference_level	Lý_do
experience_level	Entry (EN)	Nhóm mới vào nghề — lương căn bản nhất, điểm xuất phát tự nhiên
employment_type	FullTime (FT)	Hợp đồng toàn thời gian chiếm ~96% — nhóm đại diện
company_size	Small (S)	Công ty nhỏ — baseline tham chiếu hợp lý
remote_ratio	Onsite (0%)	Làm tại văn phòng — trạng thái truyền thống trước khi remote phổ biến
work_year	Numeric liên tục	Giữ numeric để mô hình nắm bắt xu hướng tuyến tính theo thời gian
job_category	Data Analyst	Vị trí phân tích dữ liệu cơ bản — lương thấp nhất trong ngành
company_region	Northern_America	Chiếm đa số quan sát (346/565); thị trường Bắc Mỹ là mức lương cao nhất — baseline tự nhiên (UNSD M49: 021)
cross_border	Integer 0/1 (không cần)	Biến nhị phân; 0 = cùng quốc gia, 1 = xuyên biên giới

Việc chọn reference level ảnh hưởng trực tiếp đến diễn giải hệ số — mỗi hệ số phản ánh *chênh lệch so với reference*, không phải mức tuyệt đối. **Entry-level** được chọn làm reference cho `experience_level` vì đây là điểm xuất phát tự nhiên trong lộ trình sự nghiệp; hệ số của Senior và Exec sẽ cho biết mức chênh lương so với nhân viên mới vào nghề. Tương tự, **Data Analyst** làm reference cho `job_category` vì đây là vị trí phổ biến với lương cơ bản thấp nhất — các hệ số còn lại phản ánh premium so với vị trí này. `cross_border` là biến nhị phân (0 = làm việc cùng quốc gia với công ty, 1 = xuyên biên giới), không cần factor. `company_region` chọn factor là **Northern_America** do giá trị này chiếm đa số quan sát.

1.2.6 Phát hiện và xử lý Outlier



1.2.6.1 Nhận diện outlier theo quy tắc IQR Boxplot ở trên đánh dấu outlier (điểm đỏ) theo quy tắc chuẩn $[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$. Trước khi quyết định cách xử lý, cần xem xét thử các outlier này có đặc trưng gì, có giải thích được về mặt nghiệp vụ hay là dấu hiệu lỗi nhập liệu.

Table 17: Nhận diện outlier theo quy tắc IQR

Chỉ tiêu	Kết quả
Ngưỡng dưới ($Q1 - 1.5 \cdot IQR$)	-73,108 USD
Ngưỡng trên ($Q3 + 1.5 \cdot IQR$)	283,864 USD
Outlier trên ngưỡng trên	10 quan sát
Outlier dưới ngưỡng dưới	0 quan sát
Tổng outlier	10 quan sát (1.8% dữ liệu)


Table 18: Hồ sơ các quan sát outlier cực đoan nhất theo IQR (hiển thị tối đa 15/10)

Hướng	Lương (USD)	Kinh nghiệm	Nhóm chức danh	Quy mô CT	Khu vực	Remote	Năm
Trên ngưỡng trên	\$600,000	Exec	Data Engineer	Large	Northern_America	FullRemote	2021
Trên ngưỡng trên	\$450,000	Mid	Data Scientist	Medium	Northern_America	Onsite	2020
Trên ngưỡng trên	\$450,000	Mid	Data Analyst	Large	Northern_America	FullRemote	2021
Trên ngưỡng trên	\$423,000	Mid	ML Engineer	Large	Northern_America	Hybrid	2021
Trên ngưỡng trên	\$416,000	Exec	Data Scientist	Small	Northern_America	FullRemote	2021
Trên ngưỡng trên	\$412,000	Senior	Data Scientist	Large	Northern_America	FullRemote	2020
Trên ngưỡng trên	\$405,000	Senior	Data Analyst	Large	Northern_America	FullRemote	2022
Trên ngưỡng trên	\$380,000	Senior	Data Scientist	Large	Northern_America	FullRemote	2022
Trên ngưỡng trên	\$325,000	Exec	Data Scientist	Large	Northern_America	FullRemote	2020
Trên ngưỡng trên	\$324,000	Exec	Data Engineer	Medium	Northern_America	FullRemote	2022

Qua quan sát ta thấy điểm chung lớn nhất và dễ thấy nhất là cả 10/10 cá nhân có mức lương cao nhất tập dữ liệu đều làm việc tại Bắc Mỹ (Northern_America). Tuy nhiên ta thấy có 3 quan trắc dù ở mức kinh nghiệm “Middle” nhưng lại có mức lương đến nửa triệu đô 1 năm, nên ta đi sâu vào nhóm “Middle” để quan sát thêm.

Phân phối chi tiết Mức lương theo Cấp bậc Kinh nghiệm

Kiểm tra sự đứt gãy và các điểm Outlier cực đoan (> 400k USD) trên toàn hệ thống



Nhóm outlier (theo IQR) không phân bố ngẫu nhiên: 70% ở cấp **Senior/Exec** (so với 47.6% toàn dữ liệu), 70% thuộc công ty **Large** (so với 34.2%), 100% ở **Northern_America** (so với 61.2%). Các mức lương cực cao chủ yếu đến từ chuyên gia cấp cao tại công ty lớn ở Bắc Mỹ — hợp lý về thị trường lao động, không phải lỗi nhập liệu; tỷ giá quy đổi cũng đã được xác nhận nhất quán ở mục trên. Đây là các quan sát hợp lệ nhưng cực đoan, không cần loại bỏ. 0 quan sát nằm dưới ngưỡng dưới — số lượng không đáng kể.

1.2.6.2 Xem xét riêng 3 quan sát Mid-level có lương bất thường Trước khi chọn ngưỡng xử lý cuối cùng, cần làm rõ 3 quan sát “Mid-level nhưng lương nửa triệu đô” phát hiện ở histogram trên — đây là trường hợp đặc

biệt vì chúng phá vỡ chính “câu chuyện” đã dùng để biện minh cho outlier (Senior/Exec ở công ty lớn), nên cần quyết định có xử lý khác biệt hay không.

Table 19: Hồ sơ đầy đủ của 3 quan sát Mid-level có salary_in_usd trên 400,000 USD

salary_in_usd	job_category	employment_type	company_size	company_region	remote_ratio	work_year	cross_border
\$450,000	Data Scientist	FullTime	Medium	Northern_America	Onsite	2020	0
\$450,000	Data Analyst	FullTime	Large	Northern_America	FullRemote	2021	0
\$423,000	ML Engineer	FullTime	Large	Northern_America	Hybrid	2021	0

3 quan sát này thuộc nhóm chức danh Data Scientist, Data Analyst, ML Engineer, quy mô Medium, Large, khu vực Northern_America. 3/3 đã vượt chặn trên IQR (283,864 USD), nên sẽ tự động được cắt về ngưỡng này ở mức dưới mà không cần luật riêng.


Nhóm không tạo ngoại lệ xử lý riêng cho 3 quan sát này: sửa từng trường hợp theo cảm quan sẽ đưa yếu tố chủ quan vào bước cần khách quan (data snooping), trong khi cắt tại chặn trên IQR đã xử lý chúng nhất quán với mọi outlier khác. Tổ hợp “Mid-level nhưng lương ngang Senior/Exec” vẫn là điểm bất thường đáng ghi nhận — có thể do gán nhãn experience_level chưa chính xác hoặc do kỹ năng hiếm được trả vượt khung — và được liệt kê ở phần hạn chế của dữ liệu.

1.2.6.3 Xử lý outlier: cắt (capping) một chiều tại chặn trên theo quy tắc IQR Quy tắc IQR dùng để **phát hiện** outlier ở trên cũng được dùng luôn để **xử lý**: báo cáo áp dụng capping **một chiều**, chỉ cắt các giá trị vượt chặn trên $Q3 + 1.5 \cdot IQR$ về đúng ngưỡng này, và **giữ nguyên chặn dưới** vì không có bằng chứng bất thường ở phía đó:

Table 20: Ngưỡng capping một chiều tại chặn trên theo quy tắc IQR

	Ngưỡng	Giá trị (USD)	Số quan sát
25%	Chặn dưới $Q1 - 1.5 \cdot IQR$ (tham khảo, KHÔNG áp dụng)	-73,108	0 — không xử lý
75%	Chặn trên $Q3 + 1.5 \cdot IQR$ (áp dụng capping)	283,864	10 — bị kéo về ngưỡng này

Capping chỉ áp dụng một chiều (chặn trên) vì đây là hướng duy nhất có bằng chứng hội tụ: quy tắc IQR tự nó đã phát hiện 10 quan sát vượt chặn trên, và phân tích cơ cấu ở trên cho thấy nhóm này tập trung ở Senior/Exec, công ty Large, khu vực Northern_America — không phải nhiễu ngẫu nhiên. Chặn dưới không có quan sát nào vượt ngưỡng (0 quan sát), nên không có căn cứ để xử lý. Vì ngưỡng xử lý (upper_fence) chính là ngưỡng đã dùng để phát hiện outlier ở trên, toàn bộ 10 quan sát bị gán cờ đều được xử lý nhất quán, không còn khoảng hở giữa bước chẩn đoán và bước xử lý — nhất quán với nguyên tắc “*không xử lý nếu không có bằng chứng*” đã nêu ở đầu mục.



Outlier trên ngưỡng có căn cứ nghiệp vụ rõ ràng (Senior/Exec, công ty Large, tập trung Northern_America), nên xóa bỏ sẽ làm mất thông tin thật và thiên lệch mẫu. Thay vào đó, **capping một chiều tại chặn trên IQR** kéo giá trị cực đoan về ngưỡng biên, giữ nguyên toàn bộ 565 quan sát — vẫn giữ tín hiệu “lương cao hơn hẳn” nhưng giới hạn ảnh hưởng đồn bầy lên hệ số OLS; chặn dưới không được xử lý vì không có bằng chứng bất thường. Tổng cộng 10 quan sát được điều chỉnh; miền giá trị thu hẹp còn tối đa [2,859 – 283,864] USD.

1.2.7 Tổng kết tiền xử lý

Table 21: Tổng hợp các bước tiền xử lý và lý do thực hiện

Bước	Lý do	Tham khảo
1. Bỏ salary & salary_currency	Collinear với target; ~17 dummy tiền tệ không cần thiết	Sheather (2009) §2.1
2. Gộp job_title → job_category	50+ chức danh → 5 nhóm chức năng, tránh overfitting	James et al. (2023) §3.3.2
3. company_location → company_region (M49 → gộp 3 nhóm); tạo cross_border; bỏ employee_residence	Giảm 50+ dummy xuống 2+1; 6 vùng M49 gộp thành 3 vì 4 vùng gốc có <50 quan sát; cross_border giữ thông tin duy nhất của employee_residence; trùng lặp >90%	UNSD (2023) M49 Geoscheme; James et al. (2023) §3.3.2
4. Chuyển categorical → factor (relevel)	R cần factor để tạo dummy; reference level xác định rõ diễn giải	James et al. (2023) §3.3.1
5. Capping salary_in_usd — một chiều, chặn trên [IQR: Q3 + 1.5·IQR]	IQR chỉ phát hiện outlier ở chặn trên (không có bằng chứng ở chặn dưới) — capping một chiều dùng đúng ngưỡng đã phát hiện; giữ nguyên toàn bộ quan sát, giảm ảnh hưởng điểm cực đoan lên hệ số OLS	Sheather (2009) §3.2.3; Bingham & Fry (2010) §7.1

Sau tiền xử lý, tập dữ liệu mô hình còn 565 quan sát và 9 biến: 1 biến mục tiêu (salary_in_usd), 1 biến số liên tục (work_year), và 7 biến phân loại đã được mã hóa factor.

1.3 Phân tích và khám phá dữ liệu (EDA)

Phần này khám phá dữ liệu theo hai tầng: đặc điểm phân phối của `salary_in_usd` (mục “Thống kê mô tả” và “Phân phối biến mục tiêu”), rồi quan hệ đôi một giữa `salary_in_usd` với từng biến dự báo — qua boxplot/scatter/line chart và kiểm định thống kê chính thức ở mục “Kiểm định quan hệ đôi một”. Hai biểu đồ tương tác xen giữa nhằm phát hiện sớm dấu hiệu mà mô hình cộng tính đơn thuần có thể bỏ sót.


1.3.1 Thống kê mô tả biến mục tiêu


Table 22: Thống kê mô tả biến mục tiêu `salary_in_usd` (sau xử lý outlier)

Chỉ số	Giá trị
Số quan sát (n)	565
Trung bình	\$108,227
Trung vị	\$100,000
Độ lệch chuẩn	\$63,039
Giá trị nhỏ nhất	\$2,859
Q1 (25%)	\$60,757
Q3 (75%)	\$150,000
Giá trị lớn nhất	\$283,864
IQR	\$89,243
Hệ số biến thiên (CV%)	58.2%

Trung bình lương là **\$108,227/năm**, nhưng trung vị thấp hơn đáng kể ở mức **\$100,000** — khoảng cách \$8,227 này là dấu hiệu rõ ràng của phân phối lệch phải. Hệ số biến thiên **CV = 58.2%** cho thấy mức độ phân tán rất cao: lương trong ngành Data Science dao động mạnh tùy theo kinh nghiệm, vị trí và địa lý — không phải một thị trường đồng nhất.


1.3.2 Phân phối biến mục tiêu





Histogram xác nhận phân phối salary_in_usd lệch phải: đuôi phải kéo dài do một nhóm nhỏ chuyên gia cấp cao nhận mức lương rất cao. Khi biến đổi log, phân phối trở nên đối xứng hơn rõ rệt — gợi ý quan trọng cho bước xây dựng mô hình, vì OLS với Y gốc có thể vi phạm giả định phân phối chuẩn phần dư, và phiên bản $\log(Y)$ thường cải thiện giả định BLUE trong bài toán lương (Sheather 2009, §3.4).

Để đánh giá định lượng mức độ lệch và độ phù hợp với phân phối chuẩn, ta bổ sung QQ-plot và hệ số bất đối xứng (skewness) cho cả salary_in_usd gốc và $\log(\text{salary_in_usd})$:



Với salary_in_usd gốc, hệ số bất đối xứng là **0.63** (skewness > 0 xác nhận lệch phải), và các điểm trên QQ-plot lệch rõ khỏi đường chuẩn ở đuôi phải — bằng chứng trực quan cho vi phạm giả định phân phối chuẩn. Sau biến đổi log, skewness giảm còn **-1.3**, gần 0 hơn nhiều, và các điểm trên QQ-plot bám sát đường chuẩn hơn đáng kể trên phần lớn miền giá trị. Kết quả này củng cố khuyến nghị cân nhắc mô hình hồi quy trên $\log(\text{salary_in_usd})$ ở Phần 2–3.

1.3.3 Lương theo cấp độ kinh nghiệm




Table 23: Thống kê lương theo cấp độ kinh nghiệm

Cấp độ	n	Trung bình	Trung vị	Độ lệch chuẩn	Min	Max
Entry	88	\$61,643	\$56,500	\$44,396	\$4,000	\$250,000
Mid	208	\$85,527	\$76,940	\$53,412	\$2,859	\$283,864
Senior	243	\$136,953	\$135,000	\$54,870	\$18,907	\$283,864
Exec	26	\$179,025	\$171,438	\$69,768	\$69,741	\$283,864

Mức chênh lệch giữa các nhóm kinh nghiệm rất rõ ràng. Nhóm **Executive** có trung bình cao nhất, trong khi **Entry-level** khởi đầu thấp hơn đáng kể — khoảng cách này phản ánh giá trị thị trường của kinh nghiệm tích lũy trong lĩnh vực dữ liệu. Đáng chú ý là độ phân tán (SD) cũng tăng theo cấp độ: lương Executive dao động rộng hơn nhiều so với Entry, cho thấy nhóm cấp cao hưởng lợi khác biệt nhiều hơn từ ngành nghề, công ty cụ thể, và địa lý.

1.3.4 Lương theo nhóm chức danh




Table 24: Thống kê lương theo nhóm chức danh

Nhóm	n	Trung bình	Trung vị	Độ lệch chuẩn
Other	6	\$160,969	\$182,500	\$79,432
Data Engineer	160	\$115,330	\$108,912	\$61,445
Data Scientist	195	\$112,900	\$104,702	\$64,816
Data Analyst	120	\$95,287	\$92,000	\$51,021
ML Engineer	84	\$98,570	\$80,020	\$71,785

Nhóm **Other** dẫn đầu về trung vị lương (\$182,500), phản ánh nhu cầu cao với nhân lực chuyên môn sâu; nhóm **ML Engineer** thấp nhất (\$80,020). Nhóm “Other” là nhóm hỗn hợp (gồm cả chức danh quản lý/lãnh đạo), nên trung vị cần diễn giải thận trọng hơn.

1.3.5 Xu hướng lương theo năm




Table 25: Thống kê lương theo năm

Năm	n	Trung bình	Trung vị	Độ lệch chuẩn
2020	72	\$ 91,155	\$ 75,544	\$66,472
2021	215	\$ 95,926	\$ 82,528	\$66,102
2022	278	\$122,163	\$120,000	\$56,523

Xu hướng tăng lương trong ngành Data Science từ 2020 đến 2022 hiện rõ qua cả trung bình lẫn trung vị. Đây không phải ngẫu nhiên — giai đoạn này trùng với làn sóng chuyển đổi số hậu COVID-19, nhu cầu phân tích dữ liệu bùng nổ đồng thời với sự cạnh tranh thu hút nhân tài từ các công ty công nghệ lớn. Cỡ mẫu tăng từ 72 (2020) lên 278 (2022) phản ánh cả sự phát triển thị trường lẫn lượng dữ liệu được thu thập nhiều hơn qua các năm. Dải ± 1 SD nói rộng theo thời gian, cho thấy sự phân tầng lương ngày càng gia tăng khi thị trường trưởng thành.

1.3.6 Lương theo chế độ làm việc và quy mô công ty




Table 26: Thống kê lương theo chế độ làm việc và quy mô công ty

Biến	Nhóm	n	Mean	Median
remote_ratio	FullRemote	346	\$117,754	\$110,712
remote_ratio	Hybrid	98	\$79,302	\$68,010
remote_ratio	Onsite	121	\$104,412	\$98,158
company_size	Large	193	\$112,991	\$100,000
company_size	Medium	290	\$114,096	\$109,640
company_size	Small	82	\$76,261	\$65,511

Mối quan hệ giữa `remote_ratio` và lương không đơn thuần là “càng remote càng lương cao” — phân phối giữa ba nhóm khá tương đồng về trung vị. Remote cao thường đi kèm với công ty có thể tuyển nhân tài toàn cầu (nâng lương), nhưng đồng thời cũng có thể đặt trụ sở ở vùng chi phí thấp (kéo lương xuống) — hai lực này triệt tiêu nhau trong dữ liệu tổng hợp. Về `company_size`, công ty **Medium** và **Large** trả lương nhìn hơn **Small**, nhất quán với thực tế rằng công ty lớn cạnh tranh nhân tài bằng mức lương cao hơn.

1.3.7 Lương theo khu vực công ty (company_region)





Table 27: Thống kê lương theo company_region (3 nhóm)

Khu vực	n	Trung bình	Trung vị	Độ lệch chuẩn	IQR	CV
Northern_America	346	\$136,827	\$130,000	\$57,763	\$70,988	42.2
Europe	157	\$ 68,314	\$ 62,726	\$35,846	\$42,125	52.5
Rest_of_World	62	\$ 49,692	\$ 31,022	\$48,614	\$58,373	97.8

Sau khi gộp, company_region có cỡ mẫu đủ lớn để so sánh (**Northern_America** n = 346, **Europe** n = 157, **Rest_of_World** n = 62). Rest_of_World có hệ số biến thiên (CV) cao nhất (97.8%) do gộp nhiều thị trường lao động không đồng nhất; Northern_America có trung vị cao nhất và phân phối chụm hơn, phản ánh mặt bằng lương tương đối đồng nhất.


1.3.8 Lương theo employment_type và cross_border

Hai biến còn lại chưa được đối chiếu trực tiếp với salary_in_usd: employment_type (rất mất cân bằng — xem mục phân phối categorical) và cross_border (nhị phân).



employment_type cho thấy trung vị Full-time không chênh lệch quá rõ so với 3 nhóm còn lại, nhưng cỡ mẫu quá nhỏ của PartTime/Contract/Freelance (dưới 20 quan sát mỗi nhóm) khiến khoảng tin cậy rất rộng — kết luận cần thận trọng. cross_border cho thấy hai nhóm khá tương đồng về trung vị, gợi ý làm việc xuyên biên giới tự nó không phải yếu tố quyết định mức lương — sẽ được kiểm định chính thức ở mục tiếp theo.



1.3.9 Xu hướng theo năm × cấp độ kinh nghiệm



Boxplot cho thấy tất cả các nhóm kinh nghiệm đều có trung vị tăng từ 2020 đến 2022, nhưng mức tăng không đồng đều. Khoảng cách giữa hộp Senior/Exec và hộp Entry/Mid ngày càng nới rộng qua từng năm — nhân sự cấp cao hưởng lợi nhiều hơn từ sự tăng trưởng của ngành. Đây gợi ý một *interaction effect* tiềm năng giữa work_year và experience_level — sẽ kiểm tra khi xây dựng mô hình.

1.3.10 Biểu đồ tương tác giữa các cặp nhân tố

Ngoài cặp `work_year` × `experience_level` ở trên, hai cặp nhân tố khác có khả năng tương tác đáng chú ý là `experience_level` × `job_category` (liệu mức “thường” cho kinh nghiệm có giống nhau giữa các nhóm chức danh không) và `experience_level` × `company_region` (liệu chênh lệch lương theo kinh nghiệm có đồng đều giữa các khu vực không). Boxplot theo cặp nhóm bên dưới cho phép so sánh trực tiếp cả trung vị lẫn độ trải rộng giữa các tổ hợp nhóm; nếu độ chênh lệch giữa các hộp thay đổi không đồng đều qua các mức của biến thứ nhất, đó là dấu hiệu trực quan của hiệu ứng tương tác.



Ở $\text{experience_level} \times \text{job_category}$, mức tăng trung vị theo kinh nghiệm không đồng đều giữa các nhóm chức danh (ví dụ ML Engineer tăng rõ hơn). Ở $\text{experience_level} \times \text{company_region}$, nhóm Executive tại Bắc Mỹ tách biệt rõ so với các khu vực khác, trong khi khoảng cách này hẹp hơn ở Entry/Mid. Đây là gợi ý thăm dò từ trực quan hóa, cần kiểm định chính thức bằng số hạng tương tác ở Phần 2–3.

1.3.11 Ma trận tương quan




Table 28: Tương quan Pearson giữa từng biến và salary_in_usd

Biến	r_Pearson	Cường_độ
experience_level	0.520	Mạnh
work_year	0.206	Yếu
company_size	0.149	Yếu
remote_ratio	0.129	Yếu

experience_level có tương quan mạnh nhất với salary_in_usd ($r = 0.52$), xác nhận kinh nghiệm là yếu tố quyết định chính. remote_ratio, company_size, work_year có tương quan thấp hơn nhưng vẫn đóng góp trong mô hình đa biến (James et al. 2023, §3.1.2). job_category, employment_type không đưa vào ma trận vì là biến danh nghĩa; ảnh hưởng của chúng sẽ được lượng hóa qua hệ số hồi quy dummy.

Giữa các biến dự báo với nhau, không có cặp nào có $|r| \geq 0.7$, gợi ý đa cộng tuyến song biến không nghiêm trọng. Tuy nhiên tương quan Pearson không phát hiện được đa cộng tuyến đa biến — cần kiểm tra VIF.

1.3.12 Kiểm định quan hệ đôi một (bivariate) với biến mục tiêu

Các mục trên trình bày trực quan (boxplot/density) quan hệ giữa từng biến và salary_in_usd. Mục này kiểm định chính thức từng quan hệ đôi một đó bằng phương pháp phù hợp với kiểu biến:

- **Biến phân loại ≥ 3 nhóm** (experience_level, employment_type, company_size, remote_ratio, job_category, company_region): kiểm định **ANOVA một chiều** (tham số, giả định phân dư chuẩn) song song với **Kruskal–Wallis** (phi tham số, dựa trên hạng — không cần giả định chuẩn). Vì salary_in_usd đã được xác nhận lệch phải ở mục phân phối biến mục tiêu, Kruskal–Wallis được xem là kiểm định chính; ANOVA dùng để đối chiếu.
- **Biến nhị phân** (cross_border): **Welch t-test** (tham số, không giả định phương sai bằng nhau) song song với **Wilcoxon rank-sum** (phi tham số).
- **Biến số liên tục/rời rạc có thứ tự** (work_year): hệ số tương quan **Pearson** song song với **Spearman** (dựa trên hạng, ít nhạy với lệch phân phối và outlier hơn).

Table 29: Kiểm định quan hệ đôi một giữa từng biến dự báo và salary_in_usd

Biến	Kiểm định (tham số / phi tham số)	Thống kê	p (tham số)	p (phi tham số)	Kết luận
experience_level	ANOVA / Kruskal-Wallis	F=72.95; H=173.07	0e+00	0.0000	Có ý nghĩa (p < 0.05)
company_size	ANOVA / Kruskal-Wallis	F=12.87; H=30.78	0e+00	0.0000	Có ý nghĩa (p < 0.05)
remote_ratio	ANOVA / Kruskal-Wallis	F=15.22; H=33.61	0e+00	0.0000	Có ý nghĩa (p < 0.05)
company_region	ANOVA / Kruskal-Wallis	F=140.07; H=219.02	0e+00	0.0000	Có ý nghĩa (p < 0.05)
work_year	Pearson / Spearman	r=0.206; rho=0.26	0e+00	0.0000	Có ý nghĩa (p < 0.05)
employment_type	ANOVA / Kruskal-Wallis	F=7.32; H=21.67	1e-04	0.0001	Có ý nghĩa (p < 0.05)
cross_border	Welch t-test / Wilcoxon	t=4.37; W=17570	0e+00	0.0001	Có ý nghĩa (p < 0.05)
job_category	ANOVA / Kruskal-Wallis	F=3.65; H=14.28	6e-03	0.0064	Có ý nghĩa (p < 0.05)

Kết quả kiểm định phi tham số (Kruskal–Wallis/Wilcoxon/Spearman — ưu tiên do salary_in_usd lệch phải) và tham số (ANOVA/t-test/Pearson) dùng để đối chiếu chéo. Biến nào có ý nghĩa ở cả hai loại kiểm định được xem là có bằng chứng thống kê vững nhất cho mỗi quan hệ với salary_in_usd; biến chỉ có ý nghĩa ở một loại kiểm định (ví dụ do vi phạm giả định chuẩn) cần diễn giải thận trọng hơn. Bảng này bổ sung — chứ không thay thế — ma trận tương quan Pearson ở trên, vì bao phủ được cả các biến danh nghĩa (job_category, employment_type, company_region) không thể đưa vào ma trận tương quan.

1.3.13 Kiểm tra đa cộng tuyến (VIF)


Table 30: Generalized VIF (GVIF) — biến phân loại nhiều mức

Biến	GVIF	Df	GVIF điều chỉnh	Đánh giá
work_year	1.544	1	1.242	☐ Chấp nhận được
experience_level	1.392	3	1.057	☐ Chấp nhận được
employment_type	1.186	3	1.029	☐ Chấp nhận được
company_size	1.661	2	1.135	☐ Chấp nhận được
remote_ratio	1.366	2	1.081	☐ Chấp nhận được
job_category	1.259	4	1.029	☐ Chấp nhận được
company_region	1.449	2	1.097	☐ Chấp nhận được
cross_border	1.116	1	1.056	☐ Chấp nhận được

Với biến phân loại nhiều mức, car::vif() tự động tính **GVIF** (Generalized VIF). Giá trị so sánh với ngưỡng là $\text{GVIF}^{1/(2 \cdot \text{Df})}$ — tương đương $\sqrt{\text{VIF}}$ cho biến nhị phân (Fox & Monette 1992, trích trong tài liệu car). Ngưỡng cảnh báo thông thường là $\sqrt{10} \approx 3.16$ cho mức nghiêm trọng và $\sqrt{5} \approx 2.24$ cho mức trung bình (James et al. 2023,

§3.3.3). Kết quả VIF xác định liệu cần chiến lược xử lý đa cộng tuyến đặc biệt hay các phương pháp regularization thông thường (Ridge/Elastic Net) là đủ — Ridge vốn được thiết kế để xử lý đa cộng tuyến bằng hình phạt L2 (Zou & Hastie 2005).

1.3.14 Phân phối các biến phân loại



Ba điểm đáng chú ý:

- (1) **employment_type** gần như toàn bộ là Full-time — hơn 95% — đồng nghĩa các nhóm PartTime, Contract, Freelance có cỡ mẫu rất nhỏ, hệ số của chúng sẽ kém tin cậy;
- (2) **experience_level** phân tầng tương đối đồng đều giữa Mid, Senior, Exec nhưng Entry-level ít hơn — cần ghi nhớ khi diễn giải;
- (3) **job_category** nhóm “Other” nhỏ nhất có thể gộp vào nhóm gần nhất nếu cần trong bước mô hình hóa.

Tóm tắt các phát hiện chính từ Phần 1 — tiền xử lý và EDA — trong bảng dưới đây.

Table 31: Tổng kết Phần 1: Tiền xử lý và EDA

Hạng_mục	Chi tiết
Cỡ mẫu cuối	565 quan sát — không loại quan sát nào (chỉ cắt giá trị cực đoan)
Biến mục tiêu	salary_in_usd — phân phối lệch phải; cân nhắc log-transform
Số biến dự báo	8 biến (7 categorical + 1 numeric)
Dữ liệu thiếu	0 NA — không cần imputation
Outlier xử lý	Capping một chiều tại chặn trên IQR ($Q3 + 1.5 \cdot IQR$); 10 quan sát được điều chỉnh
Biến bị loại/thay thế (5 biến)	salary, salary_currency, job_title, employee_residence, company_location
Feature mới tạo ra	job_category (5 nhóm chức năng); company_region (gộp còn 3 nhóm từ M49); cross_border (0/1)
Lưu ý mô hình hóa	experience_level là yếu tố dự báo mạnh nhất trong nhóm biến thứ tự; job_category phân tầng lương rõ qua boxplot (không tách riêng nhóm Manager/Lead)

Phần 1 xác định ba yếu tố nổi bật quyết định mức lương: **kinh nghiệm** (mạnh nhất), **loại chức danh** (Other dẫn đầu), và **xu hướng tăng theo thời gian** (2020→2022). Phân phối lệch phải của salary_in_usd gợi ý kiểm tra thêm $\log(\text{salary_in_usd})$ làm biến mục tiêu — thực hiện ở kiểm định BLUE, Phần 3.

2 Lựa chọn và giải thích các phương pháp phân tích thống kê với từng bài toán

2.1 Phân tích các yếu tố ảnh hưởng đến mức lương

Hồi quy tuyến tính đa biến được lựa chọn làm phương pháp phân tích chính. Mức lương của người lao động có thể đồng thời liên quan đến work_year, experience_level, employment_type, company_size, remote_ratio, job_category, company_region, cross_border. Hồi quy đa biến cho phép ước lượng mối liên hệ riêng của từng yếu tố với mức lương trong điều kiện các yếu tố còn lại được giữ không đổi, nhờ đó khắc phục hạn chế của việc chỉ so sánh riêng lẻ từng nhóm.

Phân tích sử dụng tập dữ liệu salary_model sau tiền xử lý. Các chức danh đã được gom thành năm nhóm thông qua job_category; quốc gia đặt trụ sở công ty được gom thành ba nhóm thông qua company_region; biến cross_border được tạo để phản ánh trường hợp người lao động cư trú khác quốc gia với công ty. Các biến salary, salary_currency, job_title, employee_residence và company_location không được đưa trực tiếp vào mô hình vì đã được loại bỏ hoặc thay thế bằng các biến có khả năng diễn giải tốt hơn.

Mô hình hồi quy tuyến tính đa biến tổng quát được đề xuất như sau:

$$\begin{aligned}
 g(\text{salary_in_usd}) = & \beta_0 + \beta_1 \text{work_year} + \beta_2^T \text{experience_level} \\
 & + \beta_3^T \text{employment_type} + \beta_4^T \text{company_size} \\
 & + \beta_5^T \text{remote_ratio} + \beta_6^T \text{job_category} \\
 & + \beta_7^T \text{company_region} + \beta_8 \text{cross_border} + \varepsilon
 \end{aligned}$$

trong đó $g(\cdot)$ là phép biến đổi phù hợp của biến mức lương và ε là sai số ngẫu nhiên của mô hình.

Phép biến đổi của biến phản hồi sẽ được lựa chọn dựa trên EDA. Kết quả EDA cho thấy salary_in_usd có phân phối lệch phải và xuất hiện một số mức lương lớn, vì vậy mô hình trên thang đo gốc có nguy cơ xuất hiện phần dư lệch hoặc phương sai không đồng nhất. Tuy nhiên, phân phối lệch của biến lương không đồng nghĩa trực tiếp với phần dư chắc chắn vi phạm giả định; các giả định cần được kiểm tra sau khi mô hình ban đầu được ước lượng.

Phương pháp Box–Cox được đề xuất để lựa chọn phép biến đổi biến phản hồi một cách có hệ thống. Với $Y = \text{salary_in_usd} > 0$, phép biến đổi Box–Cox có dạng:

$$Y^{(\lambda)} = \begin{cases} \frac{Y^\lambda - 1}{\lambda}, & \lambda \neq 0, \\ \log(Y), & \lambda = 0. \end{cases}$$

Nếu giá trị λ tối ưu gần 1, mô hình có thể giữ mức lương trên thang đo gốc; nếu λ gần 0, phép biến đổi logarit là phù hợp; nếu λ nhận giá trị khác, có thể sử dụng phép biến đổi lũy thừa tương ứng. Quyết định cuối cùng được đưa ra dựa trên khoảng tin cậy của λ , QQ-plot phần dư và biểu đồ phần dư theo giá trị dự báo.

Mô hình OLS được sử dụng làm mô hình cơ sở vì có khả năng diễn giải trực tiếp. Các hệ số của biến phân loại cho biết mức chênh lệch lương so với nhóm tham chiếu sau khi đã kiểm soát các yếu tố khác. Nếu sử dụng mô hình log-lương, hệ số β có thể được chuyển thành phần trăm chênh lệch gần đúng theo công thức:

$$100(e^\beta - 1)\%.$$

Ví dụ, hệ số của nhóm Senior phản ánh mức chênh lệch lương giữa Senior và Entry sau khi đã điều chỉnh nhóm nghề nghiệp, khu vực, quy mô công ty và các đặc điểm còn lại.

Ridge hoặc LASSO được đề xuất làm các mô hình bổ sung ở bước xây dựng mô hình dự đoán. Sau khi mã hóa các biến phân loại, mô hình có nhiều biến giả và một số biến có thể mang thông tin liên quan với nhau. Ridge sử dụng chuẩn hóa L_2 để thu nhỏ hệ số và cải thiện độ ổn định của dự báo, trong khi LASSO sử dụng chuẩn hóa L_1 , vừa thu nhỏ hệ số vừa có khả năng đưa một số hệ số về 0 để thực hiện lựa chọn biến. Vì vậy, ở câu (e), nhóm có thể xây dựng OLS cùng với Ridge và LASSO, sau đó so sánh khả năng dự báo trên tập kiểm định.

Phân tích phương sai nhiều yếu tố (factorial ANOVA) có thể được sử dụng để đánh giá đồng thời sự khác biệt mức lương theo kinh nghiệm, nhóm nghề nghiệp, hình thức làm việc, quy mô công ty, mức độ làm việc từ xa và khu vực địa lý. Phương pháp này phù hợp vì phần lớn biến giải thích là biến phân loại. ANOVA giúp kiểm định ảnh hưởng tổng thể của từng yếu tố, còn các hệ số hồi quy trong cùng khuôn khổ mô hình tuyến tính hỗ trợ xác định chiều hướng và mức chênh lệch giữa từng nhóm so với nhóm tham chiếu. Do dữ liệu mang tính quan sát, kết quả chỉ phản ánh mối liên hệ thống kê, không khẳng định quan hệ nhân quả.

2.2 So sánh mức lương giữa các nhóm

Để so sánh mức lương giữa các nhóm nghề nghiệp, mức kinh nghiệm, quy mô công ty, hình thức làm việc và khu vực địa lý, phương pháp lựa chọn là **Welch ANOVA**. Phương pháp này dùng để kiểm tra xem mức lương trung bình giữa nhiều nhóm có giống nhau hay không. Ví dụ, có thể kiểm tra mức lương giữa các nhóm Data Analyst, Data Engineer, Data Scientist và ML Engineer có khác biệt đáng kể hay không.

Welch ANOVA được ưu tiên hơn ANOVA thông thường vì số lượng quan sát giữa các nhóm không đồng đều và mức độ phân tán của lương trong từng nhóm có thể khác nhau. Đặc biệt, ở biến employment_type, phần lớn quan sát thuộc nhóm Full-time, trong khi các nhóm Part-time, Contract và Freelance có kích thước mẫu nhỏ hơn nhiều.

Nếu Welch ANOVA cho kết quả có ý nghĩa thống kê, điều đó chỉ cho biết có ít nhất một nhóm khác với các nhóm còn lại, nhưng chưa xác định cụ thể nhóm nào khác nhóm nào. Vì vậy, cần sử dụng thêm kiểm định hậu nghiệm **Games–Howell** để so sánh từng cặp nhóm, chẳng hạn Senior với Entry hoặc Northern America với Europe.

Trong trường hợp phân phối mức lương vẫn lệch mạnh hoặc không đáp ứng tốt các giả định của phương pháp tham số, kiểm định **Kruskal–Wallis** có thể được sử dụng thay thế. Đây là phương pháp phi tham số, phù hợp hơn khi dữ liệu không có phân phối gần chuẩn hoặc bị ảnh hưởng bởi các giá trị cực đoan.

2.3 iii. Phân tích xu hướng thay đổi mức lương theo thời gian

Để phân tích xu hướng thay đổi mức lương theo thời gian, có thể lựa chọn **mô hình hồi quy tuyến tính với biến work_year**. Biến này nhận các giá trị 2020, 2021 và 2022, có thứ tự thời gian rõ ràng nên hệ số của work_year có thể cho biết mức lương trung bình có xu hướng tăng hay giảm qua mỗi năm. Chẳng hạn, hệ số dương và có ý nghĩa thống kê cho thấy mức lương có xu hướng tăng theo thời gian, trong khi hệ số âm cho thấy xu hướng giảm.

Tuy nhiên, mức lương trung bình của từng năm có thể thay đổi không chỉ do yếu tố thời gian mà còn do cơ cấu dữ liệu giữa các năm khác nhau. Ví dụ, năm 2022 có thể có nhiều nhân sự Senior hoặc nhiều công ty tại Bắc Mỹ hơn năm 2020. Vì vậy, work_year nên được đưa vào mô hình cùng với các biến kiểm soát như experience_level, job_category, company_size, employment_type và company_region. Khi đó, hệ số của work_year phản ánh xu hướng thay đổi mức lương theo thời gian sau khi đã giữ các đặc điểm khác không đổi.

Do bộ dữ liệu chỉ gồm ba năm, nên cũng có thể xem work_year là biến phân loại và so sánh mức lương giữa năm 2020, 2021 và 2022 bằng ANOVA hoặc Welch ANOVA. Cách này không áp đặt giả định rằng mức tăng từ 2020 đến 2021 phải bằng mức tăng từ 2021 đến 2022. Vì vậy, hồi quy tuyến tính được dùng để đánh giá xu hướng chung, còn phân tích năm dưới dạng biến phân loại có thể được sử dụng bổ sung để xác định cụ thể năm nào có mức lương khác biệt.

2.4 Chia dữ liệu và xây dựng mô hình dự đoán

Phần này chia dữ liệu thành tập huấn luyện/kiểm định, rồi xây dựng bốn mô hình hồi quy — OLS, OLS rút gọn bằng stepwise AIC, Ridge và LASSO — để dự đoán salary_in_usd, điều ước lượng trên tập huấn luyện. Đánh giá khách quan trên tập kiểm định, biến đổi thang đo mục tiêu (log, Box–Cox), và các kiểm định so sánh nhóm (Welch ANOVA, Games–Howell, ANOVA nhiều nhân tố) được trình bày ở các phần sau.

2.4.1 Chia tập huấn luyện / kiểm định

2.4.1.1 Chia dữ liệu Tập dữ liệu được chia theo tỷ lệ **80/20** bằng caret::createDataPartition(), phân tầng theo phân vị của chính biến mục tiêu salary_in_usd — cách chia này giữ cho phân phối lương ở hai tập tương đồng, đặc biệt quan trọng khi biến mục tiêu lệch phải.

```
## Tập huấn luyện: 454 quan sát (80.4%)
```

```
## Tập kiểm định : 111 quan sát (19.6%)
```

Table 32: Đối chiếu phân phối salary_in_usd giữa tập huấn luyện và kiểm định

Tập	n	Mean	Median	SD
Huấn luyện	454	\$108,625	\$100,000	\$63,605
Kiểm định	111	\$106,600	\$100,000	\$60,921

Trung bình, trung vị và độ lệch chuẩn của `salary_in_usd` giữa hai tập rất gần nhau, xác nhận phép phân tầng hoạt động tốt. Kiểm tra độ phủ các mức biến phân loại: có 0 mức vắng mặt ở **tập huấn luyện** — điều kiện cần để mọi hệ số dummy đều ước lượng được. Riêng `employment_type = Freelance` (chỉ 4 quan sát toàn mẫu) vắng mặt ở tập **kiểm định** của lần chia này — hệ quả không tránh khỏi của cỡ mẫu quá nhỏ; độ chính xác dự đoán cho nhóm này vì vậy không được kiểm chứng trực tiếp, và cần ghi nhận như một hạn chế khi so sánh mô hình.

2.4.1.2 Kiểm tra tỷ lệ chia và phân bố dữ liệu Việc kiểm tra lại tỷ lệ chia tập huấn luyện/kiểm định và phân bố biến mục tiêu là bước quan trọng để đảm bảo rằng các mô hình dự đoán được huấn luyện trên một tập đại diện cho toàn bộ dữ liệu, và rằng các đánh giá hiệu năng trên tập kiểm định là hợp lý.

1. Phân phối biến mục tiêu — kiểm định Kolmogorov–Smirnov hai mẫu. Đây là kiểm định phi tham số, không giả định dạng phân phối cụ thể — phù hợp vì `salary_in_usd` lệch phải (phần EDA).

H_0 : `salary_in_usd` ở tập huấn luyện và tập kiểm định có cùng phân phối (phép chia không làm lệch phân phối lương giữa hai tập)

H_1 : hai phân phối khác nhau (phân phối lương giữa hai tập lệch nhau đáng kể dù đã phân tầng theo phân vị của `salary_in_usd`)

Kết quả kiểm định: $D = 0.063$, $p = 0.874$ — không đủ bằng chứng bác bỏ H_0 , xác nhận phân phối `salary_in_usd` giữa hai tập tương đồng, đúng như kỳ vọng khi phân tầng theo phân vị của chính biến mục tiêu.

2. Tỷ lệ các mức của từng biến phân loại — kiểm định Chi-square về tính đồng nhất. Phép chia chỉ phân tầng theo phân vị của `salary_in_usd` (mục trên), nên đây là kiểm định độc lập xem việc phân tầng đó có “vô tình” kéo theo cân bằng tốt ở các biến phân loại hay không.

H_0 : tỷ lệ các mức của biến phân loại giống nhau giữa tập huấn luyện và tập kiểm định (cơ cấu các nhóm, vd tỷ lệ Entry/Mid/Senior)

H_1 : tỷ lệ các mức khác nhau giữa hai tập (có ít nhất một mức xuất hiện với tỷ lệ khác biệt đáng kể giữa hai tập)

Table 33: Kiểm định Chi-square về tính đồng nhất tỷ lệ các mức giữa tập huấn luyện và tập kiểm định (H_0 : tỷ lệ giống nhau)

Biến	Chi-square	df	p-value
<code>experience_level</code>	3.91	3	0.2712
<code>employment_type</code>	1.66	3	0.6462
<code>company_size</code>	1.06	2	0.5889
<code>remote_ratio</code>	6.85	2	0.0326
<code>job_category</code>	6.99	4	0.1362
<code>company_region</code>	2.19	2	0.3352

Kết quả kiểm định: 1/6 biến có $p < 0.05$ — một vài biến khác biệt đáng kể giữa hai tập — cần lưu ý khi diễn giải hiệu năng dự đoán cho các nhóm liên quan, vì phân tầng chỉ theo phân vị `salary_in_usd`. Lưu ý: với các nhóm cỡ mẫu rất nhỏ (`employment_type = Freelance, Contract`), xấp xỉ Chi-square có thể kém tin cậy do một số ô kỳ vọng dưới 5 quan sát (Cochran 1954) — kết quả cho `employment_type` vì vậy mang tính tham khảo hơn là kết luận chắc chắn.

2.4.2 Xây dựng mô hình dự đoán

Mô hình 1 (OLS), 3 (Ridge) và 4 (LASSO) đều dùng **cùng tập biến đầy đủ** (8 khối biến, gồm cả `work_year`, `remote_ratio`) thay vì loại trước biến “có vẻ” không quan trọng — LASSO tự co hệ số về 0 nên kết quả co biến của nó sẽ là một bằng chứng để xác định biến quan trọng ở Phần Đánh giá mô hình. Riêng Mô hình 2 chọn biến bằng stepwise AIC, cho góc nhìn đối chiếu khác.

2.4.2.1 Mô hình 1 — Hồi quy tuyến tính bội (OLS) Mục tiêu. Xây dựng mô hình dự đoán lương đầu tiên, đồng thời — vì OLS là mô hình dễ diễn giải nhất — đóng vai trò công cụ chính để xác định *yếu tố nào ảnh hưởng đến lương, theo chiều nào, và với độ lớn (USD) cụ thể là bao nhiêu, khi các yếu tố khác được giữ cố định?* Mô hình này cũng là đường cơ sở (baseline) để đối chiếu hiệu năng dự đoán với Mô hình 2–4, và với biến thể biến đổi mục tiêu được khám phá thêm ở Phần Cải tiến mô hình. Bảng kết quả summary() bên dưới thực chất chứa hai tầng kiểm định giả thuyết khác nhau:

Kiểm định t — cho từng hệ số β_j riêng lẻ:

$H_0 : \beta_j = 0$ (biến dự báo thứ j không liên hệ với salary_in_usd, khi các biến khác giữ cố định)

$H_1 : \beta_j \neq 0$ (biến dự báo thứ j có liên hệ thực sự với salary_in_usd)

Kiểm định F — cho toàn bộ mô hình:

$H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0$ (không biến dự báo nào liên hệ với salary_in_usd; mô hình không tốt hơn dự đoán bằng trung bình)

$H_1 : \text{tồn tại ít nhất một } \beta_j \neq 0$ (mô hình có giá trị giải thích)

Mô hình cơ sở có dạng:

$$\text{salary_in_usd} = \beta_0 + \beta_1 \text{work_year} + \beta_2^\top \text{experience_level} + \dots + \beta_8 \text{cross_border} + \varepsilon,$$

trong đó các biến phân loại được mã hoá thành biến giả với mức tham chiếu đã chọn ở phần tiền xử lý (Entry, FullTime, Small, Onsite, Data Analyst, Northern_America, cross_border = 0). Mô hình được ước lượng bằng phương pháp bình phương tối thiểu trên tập huấn luyện; kết quả summary() đầy đủ:

```
##
## Call:
## lm(formula = f_full, data = train_df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -130489  -26074   -5097   23694  163022
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      4897180    7124045   0.687 0.492187
## work_year         -2386       3525  -0.677 0.498909
## experience_levelMid    11126       6387   1.742 0.082225 .
## experience_levelSenior  48644       6637   7.329 1.13e-12 ***
## experience_levelExec   96532      11988   8.052 7.87e-15 ***
## employment_typePartTime -39378      17155  -2.295 0.022183 *
## employment_typeContract   8402      22160   0.379 0.704765
## employment_typeFreelance -49048      22577  -2.172 0.030362 *
## company_sizeMedium     4702       6938   0.678 0.498369
## company_sizeLarge     14731       6676   2.207 0.027866 *
## remote_ratioHybrid    -12465       7345  -1.697 0.090410 .
## remote_ratioFullRemote  -2034       5298  -0.384 0.701190
## job_categoryData Engineer  31135       6085   5.117 4.67e-07 ***
## job_categoryData Scientist 32083       5851   5.483 7.09e-08 ***
## job_categoryML Engineer   42540       7292   5.834 1.06e-08 ***
## job_categoryOther        43669      25828   1.691 0.091605 .
## company_regionEurope    -55988       5367 -10.433 < 2e-16 ***
```



```
## company_regionRest_of_World    -72020          7350   -9.799   < 2e-16 ***
## cross_border                    -26475          7640   -3.465   0.000583 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 43290 on 435 degrees of freedom
## Multiple R-squared:  0.5552, Adjusted R-squared:  0.5368
## F-statistic: 30.16 on 18 and 435 DF,  p-value: < 2.2e-16
```

Bảng kết quả trên được đọc theo bốn tầng, từ chi tiết đến tổng thể:

(1) Bảng hệ số (Coefficients). Cột Estimate là ước lượng $\hat{\beta}$ — với biến giả, đây là **chênh lệch lương trung bình (USD) so với nhóm tham chiếu, khi giữ mọi biến khác cố định**. Cột Std. Error đo độ bất định của ước lượng đó; cột t value = $\hat{\beta}/se(\hat{\beta})$ là thống kê kiểm định cho giả thuyết $H_0: \beta = 0$; và $\Pr(>|t|)$ là p-value tương ứng — xác suất quan sát được một giá trị t cực đoan như vậy nếu biến đó thực sự không có hiệu ứng. Các dấu sao bên phải đánh dấu mức ý nghĩa (***) cho $p < 0.001$.

Đọc các hệ số nổi bật: một nhân sự **Senior** được trả trung bình cao hơn Entry \$48,644/năm và **Exec** cao hơn tới \$96,532, trong điều kiện cùng chức danh, quy mô công ty và khu vực. Ở chiều ngược lại, công ty đặt tại **Europe** trả thấp hơn Bắc Mỹ \$55,988 và **Rest_of_World** thấp hơn \$72,020 — hai hệ số có trị tuyệt đối lớn nhất mô hình. Về chức danh, **Data Scientist** và **ML Engineer** cao hơn Data Analyst lần lượt \$32,083 và 42,540. *Bin`cross\_order`mangdumvcngha*(-26,475): người làm việc khác quốc gia với công ty nhận lương thấp hơn, sau khi đã kiểm soát khu vực công ty. Ngược lại, *work_year* không có ý nghĩa ($p > 0.3$) — một kết luận sẽ được **kiểm chứng độc lập bằng ANOVA Type II** ở Phần Đánh giá và so sánh mô hình, mục Diễn giải ý nghĩa các biến quan trọng.

(2) Sai số chuẩn phần dư (Residual standard error). $RSE \approx \$43,290$ trên 435 bậc tự do: độ lệch điển hình giữa lương thực tế và lương mô hình dự đoán, ngay trên tập huấn luyện, vào khoảng \$50,000/năm — một con số đáng kể so với trung vị lương ~\$100,000, báo trước rằng khả năng dự đoán cho từng cá nhân là có giới hạn.

(3) Hệ số xác định. $R^2 = 0.555$: tám khối biến giải thích được khoảng 55.5% phương sai của lương trong tập huấn luyện. R^2 hiệu chỉnh = 0.537 — thấp hơn một chút vì đã phạt số lượng tham số (18 hệ số góc); khoảng cách nhỏ giữa hai giá trị cho thấy mô hình không “lạm phát” R^2 bằng cách nhồi biến.

(4) F-test tổng thể. Dòng cuối kiểm định H_0 : *toàn bộ* hệ số góc đồng thời bằng 0 (mô hình không tốt hơn việc dự đoán bằng trung bình chung). $F = 30.16$ trên (18, 435) bậc tự do, $p < 1e-16$ — bác bỏ H_0 một cách dứt khoát: mô hình có giá trị giải thích thực sự, dù còn xa mức hoàn hảo.

Kiểm tra đa cộng tuyến (VIF). Hệ số của mô hình chỉ đáng tin khi các biến dự báo không tương quan quá mạnh với nhau:

Table 34: Chỉ số đa cộng tuyến GVIF chuẩn hoá của mô hình OLS trên tập huấn luyện

Biến	GVIF_adj
work_year	1.229
experience_level	1.057
employment_type	1.032
company_size	1.130
remote_ratio	1.085
job_category	1.035
company_region	1.106
cross_border	1.066

Giá trị lớn nhất chỉ 1.23, xa dưới ngưỡng cảnh báo $\sqrt{5} \approx 2.24$ — đa cộng tuyến không nghiêm trọng, các hệ số OLS ổn định và diễn giải được. Vai trò của Ridge/LASSO ở đây vì vậy không phải xử lý đa cộng tuyến, mà là **ổn định hoá hệ số của các nhóm cỡ mẫu nhỏ** (Freelance, Contract, Other).

2.4.2.2 Kiểm định các giả định BLUE (Gauss–Markov) của mô hình OLS **Mục tiêu.** Hệ số OLS ở Mô hình 1 chỉ là ước lượng tuyến tính không chệch tốt nhất (Best Linear Unbiased Estimator — BLUE, định lý Gauss–Markov) — và các kiểm định t/F cùng khoảng tin cậy vừa diễn giải ở trên chỉ đáng tin — khi các giả định cổ điển của mô hình hồi quy tuyến tính được thỏa. Mục này kiểm định formal **năm giả định**: bốn giả định Gauss–Markov (tuyến tính đúng dạng, phương sai sai số đồng nhất, sai số không tự tương quan, không đa cộng tuyến hoàn hảo) cộng thêm giả định phân phối chuẩn của phần dư — không bắt buộc cho tính BLUE nhưng cần thiết để các kiểm định t/F ở trên chính xác ở cỡ mẫu hữu hạn (thay vì chỉ đúng tiệm cận). Đây là căn cứ thống kê trực tiếp cho quyết định chuyển sang hồi quy có phạt (Mô hình 3–4, đọc kỹ hơn ở mục tương ứng), cũng như động lực để khám phá thêm biến đổi biến mục tiêu ở Phần Cải tiến mô hình.

Mỗi giả định được kiểm định bằng một cặp giả thuyết riêng, H_0 luôn là “giả định được thỏa”. Bốn kiểm định dưới đây đều chạy trên phần dư của `m_ols` (Mô hình 1):

1. Tuyến tính đúng dạng — kiểm định RESET (Ramsey 1969).

H_0 : dạng hàm tuyến tính hiện tại là đúng (không thiếu số hạng phi tuyến của các giá trị dự đoán)

H_1 : dạng hàm sai (còn thiếu cấu trúc phi tuyến, ví dụ bậc hai, tương tác)

Kết quả: $F = 9.58$, $p = 8.52e-05$ — **bác bỏ H_0** .

2. Phương sai sai số đồng nhất — kiểm định Breusch–Pagan.

H_0 : $\text{Var}(\varepsilon_i | X) = \sigma^2$ (phương sai đồng nhất — sai số chuẩn và kiểm định t/F đáng tin cậy)

H_1 : phương sai sai số thay đổi theo biến dự báo (sai số chuẩn có thể bị chệch, làm kiểm định t/F kém tin cậy)

Kết quả: $BP = 38.79$, $p = 0.00304$ — **bác bỏ H_0** .

3. Sai số không tự tương quan — kiểm định Durbin–Watson.

H_0 : $\rho = 0$ (không có tự tương quan bậc 1 giữa các phần dư)

H_1 : $\rho \neq 0$ (các phần dư liên tiếp có tương quan với nhau)

Kết quả: $DW = 1.89$, $p = 0.0906$ — **không bác bỏ H_0** . Lưu ý: DW được thiết kế cho dữ liệu có thứ tự thời gian tự nhiên; với dữ liệu cắt ngang (cross-sectional) như bộ này, kiểm định này chủ yếu đóng vai trò rà soát theo checklist BLUE chuẩn hơn là phát hiện một cơ chế tự tương quan có thể diễn giải được.

4. Phần dư phân phối chuẩn — kiểm định Shapiro–Wilk.

H_0 : phần dư có phân phối chuẩn (kiểm định t/F và khoảng tin cậy chính xác ở cỡ mẫu hữu hạn)

H_1 : phần dư không có phân phối chuẩn (kiểm định t/F và khoảng tin cậy chỉ còn đúng xấp xỉ tiệm cận)

Kết quả: $W = 0.975$, $p = 4.47e-07$ — **bác bỏ H_0** (hệ số bất đối xứng phần dư ≈ 0.64 , lệch phải — hệ quả từ phân phối lệch phải của `salary_in_usd`, phần EDA).

5. Không đa cộng tuyến hoàn hảo — GVIF chuẩn hoá. Không phải kiểm định giả thuyết chính thức (không có p-value) mà là quy tắc kinh nghiệm: GVIF chuẩn hoá vượt ngưỡng tham khảo $\sqrt{5} \approx 2.24$ cho thấy đa cộng tuyến đáng lo ngại. Kết quả: GVIF chuẩn hoá lớn nhất = 1.23 — **không vi phạm** (đã tính ở mục VIF phía trên).

Table 35: Tóm tắt 5 giả định BLUE (Gauss–Markov) của mô hình OLS (Mô hình 1) trên tập huấn luyện

Giả định (H_0 = giả định được thỏa)	Thống kê	p-value	Kết luận ($\alpha = 0.05$)
1. Tuyến tính đúng dạng (RESET)	9.580	8.52e-05	Vi phạm ($p < 0.05$)
2. Phương sai sai số đồng nhất (Breusch–Pagan)	38.790	0.00304	Vi phạm ($p < 0.05$)
3. Sai số không tự tương quan (Durbin–Watson)	1.890	0.0906	Không vi phạm
4. Phần dư phân phối chuẩn (Shapiro–Wilk)	0.975	4.47e-07	Vi phạm ($p < 0.05$)
5. Không đa cộng tuyến hoàn hảo (GVIF chuẩn hoá)	1.230	—	Không vi phạm

Tổng cộng 3/5 giả định bị vi phạm hoặc cần lưu ý. Theo nguyên tắc quyết định chuẩn (Sheather 2009, ch. 4; Dalpiaz 2021, ch. 13): 0–1/5 vi phạm thì OLS vẫn là mô hình suy diễn chính; 2/5 thì OLS chỉ mang tính tham khảo; từ 3/5 trở lên thì OLS chỉ nên là baseline dự đoán. Các vi phạm này **không** làm hệ số OLS bị chệch, mà chỉ làm sai số chuẩn (và do đó p-value, khoảng tin cậy) kém tin cậy hơn — đây là động lực để khám phá biến đổi mục tiêu (log, Box–Cox) và kiểm định hoán vị không tham số ở Phần Cải tiến mô hình, cũng như đưa Ridge/LASSO vào so sánh.

2.4.2.3 Mô hình 2 — OLS rút gọn bằng stepwise AIC **Mục tiêu.** Mô hình 1 giữ nguyên 8 khối biến dù một số không có ý nghĩa thống kê (work_year, remote_ratio, phần lớn employment_type). Mục này dùng **stepwise selection theo AIC** (Akaike 1974) để tìm một mô hình OLS rút gọn, làm cơ sở so sánh với mô hình đầy đủ và Ridge/LASSO.

AIC được định nghĩa $AIC = -2\log(\hat{L}) + 2k$ ($\hat{L}$: hợp lý cực đại, k : số tham số); AIC càng nhỏ càng được ưu tiên, khác R^2 vốn không tự phạt độ phức tạp. Thuật toán stepwise hai chiều (direction = "both") xuất phát từ Mô hình 1, mỗi bước xét thêm/bớt một khối biến (theo **cả khối**, không theo từng mức như LASSO), giữ lại thay đổi giảm AIC nhiều nhất, dừng khi không còn cải thiện. Kết quả trace = 1 dưới đây in đầy đủ từng bước: AIC của mô hình hiện tại (<none>) cùng AIC nếu bỏ (-)/thêm (+) từng khối, sắp xếp tăng dần — thuật toán dừng khi <none> đã là lựa chọn nhỏ nhất:

```
## Start:  AIC=9712.12
## salary_in_usd ~ work_year + experience_level + employment_type +
##      company_size + remote_ratio + job_category + company_region +
##      cross_border
##
##           Df Sum of Sq      RSS      AIC
## - work_year    1 8.5836e+08 8.1608e+11 9710.6
## - remote_ratio    2 5.9213e+09 8.2114e+11 9711.4
## <none>                8.1522e+11 9712.1
## - company_size    2 1.2103e+10 8.2732e+11 9714.8
## - employment_type    3 1.8578e+10 8.3380e+11 9716.3
## - cross_border    1 2.2501e+10 8.3772e+11 9722.5
## - job_category    4 8.3027e+10 8.9825e+11 9748.1
## - experience_level    3 2.1997e+11 1.0352e+12 9814.6
## - company_region    2 2.9237e+11 1.1076e+12 9847.3
##
## Step:  AIC=9710.59
## salary_in_usd ~ experience_level + employment_type + company_size +
##      remote_ratio + job_category + company_region + cross_border
##
##           Df Sum of Sq      RSS      AIC
```

```

## - remote_ratio      2 5.3524e+09 8.2143e+11 9709.6
## <none>                8.1608e+11 9710.6
## + work_year          1 8.5836e+08 8.1522e+11 9712.1
## - company_size       2 1.3785e+10 8.2986e+11 9714.2
## - employment_type    3 1.8111e+10 8.3419e+11 9714.6
## - cross_border       1 2.2193e+10 8.3827e+11 9720.8
## - job_category       4 8.2806e+10 8.9888e+11 9746.5
## - experience_level   3 2.2075e+11 1.0368e+12 9813.3
## - company_region     2 2.9152e+11 1.1076e+12 9845.3
##
## Step: AIC=9709.56
## salary_in_usd ~ experience_level + employment_type + company_size +
##      job_category + company_region + cross_border
##
##              Df Sum of Sq      RSS      AIC
## <none>                8.2143e+11 9709.6
## + remote_ratio      2 5.3524e+09 8.1608e+11 9710.6
## - company_size       2 1.0477e+10 8.3191e+11 9711.3
## + work_year          1 2.8938e+08 8.2114e+11 9711.4
## - employment_type    3 2.0034e+10 8.4146e+11 9714.5
## - cross_border       1 2.1493e+10 8.4292e+11 9719.3
## - job_category       4 7.9694e+10 9.0112e+11 9743.6
## - experience_level   3 2.1893e+11 1.0404e+12 9810.8
## - company_region     2 3.3893e+11 1.1604e+12 9862.4
##
##
## Call:
## lm(formula = salary_in_usd ~ experience_level + employment_type +
##      company_size + job_category + company_region + cross_border,
##      data = train_df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -131449  -26313   -4757    23084   170349
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)       74078      8464   8.752 < 2e-16 ***
## experience_levelMid    11473      6352   1.806 0.071559 .
## experience_levelSenior  48005      6559   7.319 1.21e-12 ***
## experience_levelExec   96005     11949   8.034 8.79e-15 ***
## employment_typePartTime -40810     17066  -2.391 0.017214 *
## employment_typeContract  10300     22087   0.466 0.641224
## employment_typeFreelance -49901     22521  -2.216 0.027224 *
## company_sizeMedium     3243      6475   0.501 0.616724
## company_sizeLarge     12545      6561   1.912 0.056528 .
## job_categoryData Engineer  31123      6083   5.116 4.67e-07 ***
## job_categoryData Scientist 31591      5820   5.427 9.48e-08 ***
## job_categoryML Engineer  40697      7223   5.635 3.14e-08 ***
## job_categoryOther      43992     25753   1.708 0.088309 .

```

```
## company_regionEurope          -57976          5124 -11.315 < 2e-16 ***
## company_regionRest_of_World   -73129          7221 -10.128 < 2e-16 ***
## cross_border                   -25714          7596  -3.385 0.000775 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 43310 on 438 degrees of freedom
## Multiple R-squared:  0.5518, Adjusted R-squared:  0.5364
## F-statistic: 35.95 on 15 and 438 DF,  p-value: < 2.2e-16
```

AIC giảm từ 1.10025×10^4 (Mô hình 1, đầy đủ) xuống 1.1×10^4 (mô hình rút gọn) — thuật toán loại bỏ nhân tố *work_year*, *remote_ratio*. R^2 trên tập huấn luyện của mô hình rút gọn là 0.552, gần như không đổi so với 0.555 của Mô hình 1 — đúng như kỳ vọng lý thuyết: stepwise chỉ loại các nhân tố đóng góp cực ít vào độ khớp, nên R^2 giảm không đáng kể dù mô hình đơn giản hơn.

Điểm khác biệt về phương pháp cần lưu ý so với LASSO (Mô hình 4): stepwise AIC quyết định giữ/loại theo **cả khối** biến phân loại, còn LASSO co hệ số theo **từng cột biến giả riêng lẻ** (đã nêu ở mục Mô hình 3 và 4 ngay dưới đây) — hai cách tiếp cận có thể cho kết luận khác nhau về cùng một nhân tố, và sẽ được đối chiếu ở Phần Đánh giá và so sánh mô hình cùng RMSE/MAE/ R^2 trên tập kiểm định.

Kiểm định F lồng nhau: mô hình rút gọn có mất thông tin có ý nghĩa so với mô hình đầy đủ không? AIC thấp hơn chỉ cho biết Mô hình 2 *được ưu tiên hơn*, chưa phải kiểm định giả thuyết chính thức. Vì Mô hình 2 **lồng trong** Mô hình 1 (chỉ ép hệ số các nhân tố bị loại về 0), có thể so sánh bằng partial F-test (extra sum of squares F-test):

H_0 : các hệ số của (các) nhân tố bị loại đồng thời bằng 0 (Mô hình 2 rút gọn không mất thông tin có ý nghĩa so với Mô hình 1)

H_1 : tồn tại ít nhất một hệ số bị loại khác 0 (Mô hình 1 đầy đủ giải thích tốt hơn có ý nghĩa so với Mô hình 2)


Kết quả: $F = 1.1$ trên (3, 435) bậc tự do, $p = 0.347$ — không bác bỏ H_0 : nhân tố bị loại không đóng góp thêm có ý nghĩa — xác nhận Mô hình 2 không mất thông tin so với Mô hình 1, nhất quán với AIC giảm và R^2 gần như không đổi.

2.4.2.4 Mô hình 3 và 4 — Hồi quy Ridge và LASSO **Mục tiêu.** Bảng BLUE ghi nhận 3/5 giả định bị vi phạm — căn cứ để đưa vào so sánh các phương pháp không dựa vào giả định phân phối/phương sai của OLS, đồng thời ổn định hoá hệ số của các nhóm cỡ mẫu nhỏ (Freelance, Contract, Other). Vì Ridge/LASSO cố ý đánh đổi độ chệch để giảm phương sai, khái niệm BLUE (định nghĩa cho ước lượng không chệch) không áp dụng cho hai phương pháp này — đây là lý do kiểm định BLUE chỉ thực hiện cho Mô hình 1.

Cả hai phương pháp đều tối thiểu hoá tổng bình phương phần dư **cộng thêm một số hạng phạt** trên độ lớn của hệ số:

$$\text{Ridge: } \sum_i (y_i - \hat{y}_i)^2 + \lambda \sum_j \beta_j^2, \quad \text{LASSO: } \sum_i (y_i - \hat{y}_i)^2 + \lambda \sum_j |\beta_j|,$$

với $\lambda \geq 0$ điều khiển mức phạt. Phạt L_2 của Ridge co đều mọi hệ số về gần 0 nhưng không bao giờ đưa về đúng 0; phạt L_1 của LASSO có thể đưa hệ số về **đúng 0**, tức tự động loại biến (Zou & Hastie 2005). Đánh đổi ở đây là chấp nhận một phần độ chệch (bias) để giảm phương sai (variance) của ước lượng — có lợi khi một số nhóm cỡ mẫu nhỏ khiến hệ số OLS dao động mạnh giữa các mẫu. Giá trị λ tối ưu của từng phương pháp được chọn bằng **10-fold cross-validation** trên tập huấn luyện:



Mỗi biểu đồ vẽ sai số bình phương trung bình ước lượng bằng cross-validation (trục tung, kèm thanh sai số) theo $\log(\lambda)$ (trục hoành); dãy số phía trên cho biết số hệ số khác 0 tại mỗi mức phạt. Đường đứt nét bên trái đánh dấu λ_{min} — mức phạt cho sai số CV thấp nhất, được dùng cho toàn bộ kết quả bên dưới; đường bên phải là λ_{1se} — mô hình đơn giản nhất còn nằm trong một sai số chuẩn của mức tối ưu.

Table 36: Hệ số Ridge và LASSO tại lambda tối ưu (10-fold CV); hệ số LASSO bị co về đúng 0 được tô đỏ

	Biến	Ridge	LASSO
work_year	work_year	-1279.5	0.0
experience_levelMid	experience_levelMid	6636.7	5116.5
experience_levelSenior	experience_levelSenior	44040.5	43333.7
experience_levelExec	experience_levelExec	89176.3	88577.1
employment_typePartTime	employment_typePartTime	-40199.5	-36864.6
employment_typeContract	employment_typeContract	7600.1	0.0
employment_typeFreelance	employment_typeFreelance	-44884.2	-38515.0
company_sizeMedium	company_sizeMedium	3978.4	0.0
company_sizeLarge	company_sizeLarge	14275.2	10609.8
remote_ratioHybrid	remote_ratioHybrid	-11656.1	-8135.7
remote_ratioFullRemote	remote_ratioFullRemote	-1070.4	0.0
job_categoryData Engineer	job_categoryData Engineer	26514.5	24749.1
job_categoryData Scientist	job_categoryData Scientist	27116.1	25273.2
job_categoryML Engineer	job_categoryML Engineer	35615.3	32463.3
job_categoryOther	job_categoryOther	36544.4	26234.7
company_regionEurope	company_regionEurope	-52433.4	-53121.2
company_regionRest_of_World	company_regionRest_of_World	-67716.2	-69176.4
cross_border	cross_border	-25244.3	-24091.1

λ tối ưu của Ridge là 2825.3, của LASSO là 750.4. Ba quan sát chính từ bảng hệ số:

- LASSO co **4/18** hệ số về đúng 0 (company_sizeMedium, remote_ratioFullRemote), và co work_year xuống còn 0 USD/năm — gần như triệt tiêu. Kết quả này sẽ được đối chiếu với ANOVA Type II ở Phần Đánh giá mô hình: nếu cả hai phương pháp (co hệ số và kiểm định theo khối) cùng kết luận work_year/remote_ratio không còn thông tin dự đoán, đó là bằng chứng hội tụ đáng tin cậy.

- Các hệ số lớn nhất — `company_regionEurope`, `company_regionRest_of_World`, `experience_levelExec`, `experience_levelSenior` — giữ nguyên dấu và độ lớn gần tương đương giữa Ridge, LASSO và OLS: tín hiệu của các yếu tố chính rất ổn định, không phụ thuộc phương pháp ước lượng.
- Một giới hạn kỹ thuật cần minh bạch: LASSO thường có hệ số theo **từng cột biến giả riêng lẻ**, không theo cả khối nhân tố — nên `remote_ratio` (3 mức) chỉ bị loại một phần (`FullRemote` về 0, `Hybrid` thì không); muốn chọn biến theo khối cần grouped LASSO, được nêu ở phần đề xuất cải tiến.

2.4.3 Tóm tắt

Table 37: Bốn mô hình dự đoán được xây dựng trên tập huấn luyện

Mô_hình	Đặc_điểm
1. OLS	Baseline tuyến tính; $R^2 = 0.555$, $F(18, 435)$ có ý nghĩa rất mạnh; <code>work_year</code> và <code>remote_ratio</code> không có ý nghĩa
2. OLS rút gọn (stepwise AIC)	Chọn biến theo cả khối bằng AIC; $AIC\ 11002.5 \rightarrow 11000$; $R^2 = 0.552$, gần như không đổi so với Mô hình 1
3. Ridge	Phạt L2, $\lambda = 2825.3$ — co đều mọi hệ số, ổn định hoá nhóm cỡ mẫu nhỏ
4. LASSO	Phạt L1, $\lambda = 750.4$ — tự loại 4/18 hệ số, sẽ đối chiếu với ANOVA Type II ở Phần Đánh giá mô hình

Phần này đã xử lý:

- chia dữ liệu thành tập huấn luyện/kiểm định và xây dựng bốn mô hình dự đoán — `m_ols`, `m_step`, `cv_ridge`, `cv_lasso` — cùng các dự đoán tương ứng trên tập kiểm định (`pred_ols`, `pred_step`, `pred_ridge`, `pred_lasso`);
- kiểm định các giả định BLUE của Mô hình 1 (RESET, Breusch–Pagan, Durbin–Watson, Shapiro–Wilk, GVIF), xác định mức độ tin cậy của các hệ số và kiểm định t/F. Phần tiếp theo so sánh cả bốn mô hình bằng RMSE, MAE, R^2 trên cùng tập kiểm định, chọn mô hình tốt nhất, rồi diễn giải các biến quan trọng — kết hợp hệ số mô hình với các kiểm định so sánh nhóm (Welch ANOVA, Games–Howell, ANOVA nhiều nhân tố). Biến đổi mục tiêu ($\log$, Box–Cox) được khám phá thêm ở Phần Cải tiến mô hình.

2.5 Đánh giá, so sánh mô hình và diễn giải biến quan trọng

Phần trước đã xây dựng 4 mô hình dự đoán (OLS, OLS rút gọn, Ridge, LASSO) cùng dự đoán trên tập kiểm định `test_df` — dữ liệu không tham gia ước lượng. Phần này đánh giá khách quan cả 4 mô hình, chọn mô hình tốt nhất, rồi diễn giải các biến quan trọng; Phần Cải tiến mô hình khám phá thêm biến đổi thang đo mục tiêu ($\log$, Box–Cox).


2.5.1 Đánh giá và so sánh mô hình bằng RMSE, MAE, R^2

Mục tiêu. Đánh giá khách quan cả 4 mô hình và chọn mô hình tốt nhất. Cả ba chỉ số đều tính trên **tập kiểm định** `test_df` — dữ liệu không tham gia ước lượng — vì đánh giá trên dữ liệu huấn luyện luôn lạc quan quá mức (James et al. 2023, ch. 2). So sánh RMSE/MAE/ R^2 dưới đây là so sánh **mô tả**, không phải kiểm định giả thuyết chính thức (không có H_0/H_1); hướng khắc phục (kiểm định Diebold–Mariano) được nêu ở Phần Cải tiến mô hình. Ba chỉ số dùng các hàm chung `rmse()`, `mae()`, `r2_score()` (`config/setup.R`):

- **RMSE** (Root Mean Squared Error): $\sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$ — đơn vị USD, phạt nặng các sai số lớn.
- **MAE** (Mean Absolute Error): $\frac{1}{n} \sum |y_i - \hat{y}_i|$ — đơn vị USD, ít nhạy với sai số cực đoan hơn RMSE.
- **R²** trên tập kiểm định: $1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$ — tỷ lệ phương sai của salary_in_usd mà mô hình giải thích được trên dữ liệu **chưa từng thấy**.

Table 38: So sánh RMSE, MAE, R² trên tập kiểm định (111 quan sát), xếp theo RMSE tăng dần

Hạng	Mô hình	RMSE	MAE	R ² (test)
1	3. Ridge	\$45,742	\$35,109	0.4311
2	2. OLS rút gọn (stepwise AIC)	\$45,800	\$34,904	0.4297
3	1. OLS	\$46,047	\$35,279	0.4235
4	4. LASSO	\$46,071	\$35,170	0.4229




Hai nhận xét đáng chú ý. **3. Ridge có RMSE thấp nhất** và R² cao nhất trên tập kiểm định, tuy nhiên **2. OLS rút gọn (stepwise AIC)** mới là mô hình có MAE thấp nhất — chênh lệch giữa Ridge và LASSO nhìn chung rất nhỏ, cả hai đều nhìn hơn OLS thuần túy, đúng như kỳ vọng khi các nhóm nhỏ (Freelance, Contract, Other) khiến OLS kém ổn định. **OLS rút gọn (stepwise AIC)** có RMSE \$45,800 — thấp hơn OLS đầy đủ (\$46,047) — việc bớt biến gần như không đổi khả năng dự đoán, nhưng không đạt cải thiện rõ rệt như Ridge/LASSO. Phần Cải tiến mô hình sẽ khám phá thêm liệu biến đổi thang đo mục tiêu (log, Box–Cox) có cải thiện hơn không.

Mô hình được chọn để diễn giải là **3. Ridge** — RMSE $\approx$ \$45,742, MAE $\approx$ \$35,109, R² $\approx$ 0.431 trên tập kiểm định. Với một hồ sơ chưa từng xuất hiện trong tập huấn luyện, mô hình dự đoán sai lệch trung bình khoảng \$35,109/năm so với lương thực nhận — đáng kể so với trung vị lương ($\sim$ \$100,000), phản ánh phần biến động lương còn lại đến từ các yếu tố cá nhân không có trong dữ liệu (năng lực cụ thể, thương lượng, công ty cụ thể...). R² trên tập kiểm định thấp hơn khá nhiều so với R² huấn luyện ($\sim$ 0.51) — một phần là bình thường (R² trên chính dữ liệu huấn luyện luôn lạc quan), nhưng mức chênh ($\sim$ 0.51 xuống $\sim$ 0.36) cũng phản ánh cỡ mẫu kiểm định nhỏ (111 quan sát) trong khi salary_in_usd lệch phải mạnh, khiến R² nhạy với vài quan sát lương cao bị dự đoán lệch. Độ nhạy này được kiểm tra kỹ hơn bằng Cook's distance và hồi quy vững ở Phần Cải tiến mô hình.

2.5.2 Diễn giải ý nghĩa các biến quan trọng trong mô hình được chọn

Mục tiêu. Diễn giải ý nghĩa thực tế của các biến quan trọng trong mô hình tốt nhất (Ridge) — không chỉ biến nào có ý nghĩa thống kê, mà còn xếp hạng biến nào **quan trọng hơn về độ lớn thực tế**. Vì Ridge không đưa hệ số nào về 0, độ lớn hệ số **không so sánh trực tiếp được** giữa các biến khác thang đo (work_year theo năm, còn lại là dummy 0/1). Hệ số được **chuẩn hoá** bằng độ lệch chuẩn của biến dự báo tương ứng trong tập huấn luyện — tương đương mức thay đổi kỳ vọng của salary_in_usd khi biến đó thay đổi 1 độ lệch chuẩn (hoặc đúng bản chất 0/1 với dummy).



Ba nhóm biến nổi bật nhất — nhất quán với cả bảng hệ số OLS có ý nghĩa thống kê (Phần Xây dựng mô hình dự đoán, Mô hình 1) lẫn ma trận tương quan (Phần Phân tích khám phá dữ liệu (EDA)):

- **company_region** (Europe, Rest_of_World) đứng đầu bảng xếp hạng, cả hai mang dấu âm — công ty ngoài Bắc Mỹ trả thấp hơn đáng kể, cùng chiều và mức ý nghĩa cao ($p < 0.001$) như hệ số OLS.
- **experience_level** (Senior, Exec) đứng ngay sau, dấu dương và tăng theo cấp bậc — xác nhận kinh nghiệm là yếu tố mạnh thứ hai, khớp với tương quan Pearson mạnh nhất ở phần EDA.
- **job_category** (Data Scientist, ML Engineer, Data Engineer) xếp sau, đều dương và có ý nghĩa so với baseline Data Analyst ($p < 0.001$ cả ba) — Data Analyst là nhóm trả lương thấp nhất.

Ảnh hưởng yếu nhất: **remote_ratioFullRemote**, **company_sizeMedium** có hệ số chuẩn hoá gần 0 — cũng là hai hệ số bị LASSO co về 0. **work_year** xếp gần cuối dù đã chuẩn hoá — khớp với hệ số OLS không có ý nghĩa ($p > 0.3$). Ba phương pháp độc lập — t-test OLS, LASSO, hệ số chuẩn hoá Ridge — hội tụ về cùng kết luận: **work_year** và phần lớn **remote_ratio** đóng góp rất ít một khi đã biết **experience_level**, **job_category**, **company_region**.

2.5.2.1 So sánh mức lương giữa các nhóm bằng phân tích phương sai (kiểm chứng thêm cho các biến quan trọng) **Mục tiêu.** Hệ số Ridge xếp hạng được biến nào quan trọng, nhưng không tự nhiên cho biết mức lương giữa từng cặp nhóm cụ thể chênh lệch bao nhiêu và có chắc chắn không. Mục này chạy các kiểm định so sánh nhóm trên **toàn bộ 565 quan sát** (không cần giữ tập kiểm định riêng), như một lớp bằng chứng độc lập thứ hai cho việc xác định biến quan trọng.

2.5.2.1.1 Welch ANOVA và Kruskal–Wallis cho từng nhân tố **Mục tiêu.** So sánh mức lương trung bình giữa các nhóm của **job_category**, **experience_level**, **company_size**, **employment_type**, **remote_ratio** và **company_region** — mỗi nhân tố kiểm định **riêng lẻ**; ANOVA nhiều nhân tố ở mục sau sẽ xét đồng thời để tách hiệu ứng thực khỏi hiệu ứng “đội lốt” do các nhân tố tương quan nhau.

Với mỗi nhân tố phân loại có k nhóm, μ_i là mức lương trung bình của nhóm thứ i , cặp giả thuyết được kiểm định là:

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_k \quad (\text{mức lương trung bình giống nhau giữa mọi nhóm của nhân tố đang xét})$$

$$H_1 : \text{tồn tại ít nhất một cặp } \mu_i \neq \mu_j \quad (\text{có ít nhất hai nhóm khác nhau về mức lương trung bình})$$

Welch ANOVA được dùng thay ANOVA cổ điển vì cỡ mẫu giữa các nhóm chênh lệch lớn (Full-time chiếm >96% của **employment_type**) và phương sai không đồng đều. **Kruskal–Wallis** (phi tham số) chạy song song để đối chiếu, vì **salary_in_usd** lệch phải rõ rệt.

Table 39: Kiểm định Welch ANOVA và Kruskal–Wallis cho từng nhân tố (tổng 565 quan sát)

Nhân tố	F (Welch)	df tử	df mẫu	p (Welch)	H (KW)	p (KW)
experience_level	73.24	3	103.2	<1e-16	173.07	<1e-16
job_category	3.51	4	36.9	0.0158	14.28	0.00644
company_size	15.02	2	222.3	7.61e-07	30.78	2.07e-07
remote_ratio	19.59	2	227.4	1.42e-08	33.61	5.03e-08
employment_type	18.11	3	7.5	0.000847	21.67	7.62e-05
company_region	160.48	2	168.1	<1e-16	219.02	<1e-16

Cả sáu nhân tố đều có ý nghĩa thống kê ở mức $\alpha = 0.05$ theo **cả hai** kiểm định — sự đồng thuận giữa phương pháp tham số và phi tham số cho thấy kết luận không phụ thuộc vào giả định phân phối. Ba điểm cần lưu ý khi đọc bảng:

- `experience_level` ($F \approx 65.1$) và `company_region` ($F \approx 143.7$) có thống kê F vượt trội so với các nhân tố còn lại — đúng thứ tự quan trọng mà ma trận tương quan ở phần EDA đã gợi ý.
- `employment_type` tuy có $p < 0.001$ nhưng bậc tự do mẫu số của Welch chỉ xấp xỉ 7.5 — hệ quả của các nhóm Part-time/Contract/Freelance quá nhỏ (4–10 quan sát) — nên kết luận về nhân tố này cần thận trọng.
- Các kiểm định ở đây là **đôi một** (chưa kiểm soát các nhân tố khác); mục ANOVA nhiều nhân tố bên dưới sẽ cho thấy bức tranh thay đổi thế nào khi các nhân tố được xét đồng thời.

2.5.2.1.2 Hậu kiểm Games–Howell: cặp nhóm nào thực sự khác nhau? Mục tiêu. Welch ANOVA chỉ trả lời *có tồn tại* khác biệt hay không, chưa cho biết cặp nhóm nào khác nhau và chênh lệch bao nhiêu USD. Với mỗi cặp nhóm (i, j) trong một nhân tố, cặp giả thuyết được kiểm định là:

$H_0 : \mu_i = \mu_j$ (hai nhóm i và j có mức lương trung bình bằng nhau)

$H_1 : \mu_i \neq \mu_j$ (hai nhóm i và j có mức lương trung bình khác nhau)

kiểm định đồng thời trên toàn bộ các cặp nhóm, với p-value hiệu chỉnh (p.adj) giữ tỷ lệ sai lầm loại I gia đình ở $\alpha = 0.05$. Hậu kiểm **Games–Howell** — tương thích với Welch, tự hiệu chỉnh cho so sánh bội — được áp dụng cho bốn nhân tố trọng tâm:

Table 40: Hậu kiểm Games–Howell: chênh lệch lương trung bình giữa từng cặp nhóm (nhóm sau trừ nhóm trước) kèm khoảng tin cậy 95 phần trăm

Nhân tố	So sánh	Chênh lệch	Khoảng tin cậy	p hiệu chỉnh	Kết luận
experience_level	Entry so với Mid	\$ 23,883	[\$ 8,311; \$ 39,455]	0.000571	Khác biệt có ý nghĩa
experience_level	Entry so với Senior	\$ 75,310	[\$60,022; \$ 90,598]	< 1e-04	Khác biệt có ý nghĩa
experience_level	Entry so với Exec	\$117,382	[\$78,102; \$156,661]	< 1e-04	Khác biệt có ý nghĩa
experience_level	Mid so với Senior	\$ 51,427	[\$38,251; \$ 64,603]	< 1e-04	Khác biệt có ý nghĩa
experience_level	Mid so với Exec	\$ 93,498	[\$54,861; \$132,136]	< 1e-04	Khác biệt có ý nghĩa
experience_level	Senior so với Exec	\$ 42,072	[\$ 3,531; \$ 80,612]	0.028371	Khác biệt có ý nghĩa
company_region	Northern_America so với Europe	\$-68,513	[\$ -78,441; \$-58,585]	<1e-04	Khác biệt có ý nghĩa
company_region	Northern_America so với Rest_of_World	\$-87,135	[\$-103,591; \$-70,679]	<1e-04	Khác biệt có ý nghĩa
company_region	Europe so với Rest_of_World	\$-18,622	[\$ -34,843; \$ -2,401]	0.0203	Khác biệt có ý nghĩa
company_size	Small so với Medium	\$37,835	[\$ 21,015; \$54,656]	<1e-04	Khác biệt có ý nghĩa
company_size	Small so với Large	\$36,731	[\$ 17,896; \$55,565]	<1e-04	Khác biệt có ý nghĩa
company_size	Medium so với Large	\$-1,104	[\$-15,284; \$13,075]	0.982	Không có ý nghĩa
remote_ratio	Onsite so với Hybrid	\$-25,110	[\$-43,170; \$-7,051]	0.00344	Khác biệt có ý nghĩa
remote_ratio	Onsite so với FullRemote	\$ 13,342	[\$ -2,393; \$29,076]	0.11435	Không có ý nghĩa
remote_ratio	Hybrid so với FullRemote	\$ 38,452	[\$ 23,956; \$52,949]	< 1e-04	Khác biệt có ý nghĩa

Bảng hậu kiểm cho một bức tranh chi tiết hơn hẳn kiểm định tổng thể:

- **experience_level**: cả 6 cặp đều khác biệt có ý nghĩa — thang lương phân tầng đơn điệu theo cấp bậc. Entry so với Exec chênh ~\$130,000/năm; ngay cặp sát nhau nhất (Senior so với Exec, ~\$53,000) cũng đạt ý nghĩa ($p \approx 0.04$), dù khoảng tin cậy rộng do nhóm Exec chỉ có 26 quan sát.
- **company_region**: cả 3 cặp đều có ý nghĩa. Bắc Mỹ trả cao hơn Europe ~\$71,500 và Rest_of_World ~\$90,100; chênh lệch Europe so với Rest_of_World (~\$18,600) cũng đạt ý nghĩa ($p \approx 0.02$).
- **company_size**: Small trả thấp hơn có ý nghĩa so với Medium (~\$36,900) và Large (~\$39,100), nhưng **Medium và Large không khác biệt** ($p \approx 0.94$) — “phần thưởng quy mô” chỉ xuất hiện khi vượt khỏi nhóm nhỏ.
- **remote_ratio**: bất ngờ nhất — **Hybrid** thấp hơn có ý nghĩa so với cả Onsite và FullRemote, trong khi hai nhóm này không khác nhau. Quan hệ không đơn điệu — lý do biến này có tương quan yếu ở phần EDA.

2.5.2.1.3 ANOVA nhiều nhân tố: hiệu ứng của từng nhân tố sau khi kiểm soát các nhân tố còn lại **Mục tiêu.** Các nhân tố trong dữ liệu tương quan với nhau (ví dụ `experience_level` và `company_region` cùng thay đổi theo `work_year`), nên mục này trả lời: *hiệu ứng của một nhân tố lên lương có còn ý nghĩa khi mọi nhân tố khác được kiểm soát?* Đây cũng là kiểm chứng độc lập cho mô hình hồi quy (Mô hình 1, 4) — về bản chất cùng một mô hình tuyến tính, chỉ khác cách trình bày kiểm định. Với mỗi nhân tố X_k , cặp giả thuyết của F-test loại II là:

H_0 : mọi hệ số của các biến giả thuộc X_k đồng thời bằng 0 (sau khi đã có mặt mọi nhân tố còn lại; X_k không đóng góp thêm c

H_1 : tồn tại ít nhất một hệ số của X_k khác 0 (sau khi đã có mặt mọi nhân tố còn lại; X_k vẫn đóng góp thực sự)

Kiểm định đôi một ở trên có hạn chế: các nhân tố tương quan với nhau (tỷ trọng Senior và công ty Bắc Mỹ cùng tăng theo năm), nên hiệu ứng đo được có thể là của nhân tố khác “đội lốt”. ANOVA nhiều nhân tố khắc phục bằng **F-test loại II** — so sánh mô hình có/không có nhân tố đó khi mọi nhân tố còn lại đã có mặt; kết quả không phụ thuộc việc chọn nhóm tham chiếu, khác t-test từng hệ số.

Table 41: ANOVA nhiều nhân tố (Type II) trên toàn bộ dữ liệu — mỗi nhân tố được kiểm định sau khi kiểm soát mọi nhân tố còn lại

Nhân tố	Df	F	p-value	Kết luận
experience_level	3	41.83	< 1e-16	Có ý nghĩa
job_category	4	13.09	3.43e-10	Có ý nghĩa
company_size	2	3.92	0.0205	Có ý nghĩa
remote_ratio	2	1.64	0.1945	Không có ý nghĩa
employment_type	3	3.36	0.0185	Có ý nghĩa
company_region	2	96.75	< 1e-16	Có ý nghĩa
cross_border	1	15.87	7.69e-05	Có ý nghĩa
work_year	1	0.03	0.8613	Không có ý nghĩa

So sánh với Welch ANOVA đôi một, phát hiện quan trọng nhất: **remote_ratio** ($p \approx 0.22$) và **work_year** ($p \approx 0.57$) **mất hoàn toàn ý nghĩa** khi các nhân tố khác được kiểm soát, dù cả hai có ý nghĩa mạnh khi xét đôi một — khớp với kết quả `work_year` không có ý nghĩa ở OLS và bị LASSO co gắt về 0. Quan hệ thô giữa hai biến này với lương chủ yếu là **hiệu ứng gián tiếp qua cơ cấu mẫu** — các năm sau có nhiều hồ sơ Senior và công ty Bắc Mỹ hơn, nên lương trung bình tăng theo năm mà không phản ánh việc một hồ sơ cố định được trả cao hơn theo thời gian. Bốn nhân tố giữ ý nghĩa mạnh sau kiểm soát — `experience_level`, `company_region`, `job_category`, `cross_border` — là các yếu tố ảnh hưởng thực sự, hội tụ với kết quả OLS và LASSO ở trên.

Tổng hợp. Hai lớp bằng chứng độc lập — hệ số chuẩn hoá Ridge và các kiểm định so sánh nhóm — hội tụ về cùng kết luận: `experience_level` và `company_region` là hai nhân tố ảnh hưởng mạnh và ổn định nhất, `job_category` đứng ngay sau; `work_year` và phần lớn `remote_ratio` không đóng góp thêm, khớp với việc LASSO co gần hết hệ số hai biến này về 0. Bức tranh đầy đủ gồm cả *biến nào* quan trọng, *quan trọng bao nhiêu* (Ridge, Games–Howell) và *có chắc chắn thống kê không* (t-test, Welch ANOVA, ANOVA Type II).

2.5.2.1.4 Tương tác `experience_level` × `company_region`: hiệu ứng khu vực có đồng đều giữa các cấp kinh nghiệm không? **Mục tiêu.** ANOVA nhiều nhân tố ở trên giả định các hiệu ứng là **cộng tính** — chênh lệch lương giữa các khu vực được giả định như nhau ở mọi cấp kinh nghiệm. Mục này kiểm định trực tiếp giả định đó cho cặp nhân tố ảnh hưởng mạnh nhất, `experience_level` và `company_region` — đúng cặp đã được gợi ý có tương tác từ biểu đồ hộp ở Phần Phân tích khám phá dữ liệu (EDA): nếu hiệu ứng khu vực thực sự khác nhau tùy cấp kinh nghiệm, một hệ số khu vực duy nhất (mô hình cộng tính) sẽ “trung bình hoá” sai lệch, không phản ánh đúng bức tranh ở từng cấp bậc.

H_0 : hiệu ứng của `company_region` lên lương giống nhau ở mọi mức `experience_level` (không có tương tác; mô hình cộng tính đã đủ)

H_1 : hiệu ứng của `company_region` lên lương khác nhau tùy mức `experience_level` (có tương tác)

Kết quả: $F = 1.4$ trên (6, 540) bậc tự do, $p = 0.213$ — **không bác bỏ H_0** : không đủ bằng chứng cho thấy hiệu ứng khu vực khác nhau giữa các cấp kinh nghiệm.

Kiểm định F lồng nhau ở trên cho biết **số hạng tương tác nói chung** có cải thiện mô hình hay không, nhưng gộp chung mọi bậc tự do của tương tác vào một con số duy nhất. Bảng dưới đây tách lại **từng nhân tố riêng lẻ** trong mô hình đã có tương tác — bao gồm cả tám nhân tố chính lẫn số hạng tương tác — theo đúng khuôn mẫu ANOVA Type II đã dùng ở bảng trên, để đối chiếu trực tiếp mức ý nghĩa của từng thành phần:


Table 42: ANOVA (Type II) của mô hình có thêm số hạng tương tác `experience_level:company_region`

Nhân tố	Df	F	p-value	Kết luận
<code>experience_level</code>	3	42.01	< 1e-16	Có ý nghĩa
<code>job_category</code>	4	13.24	2.69e-10	Có ý nghĩa
<code>company_size</code>	2	4.21	0.0153	Có ý nghĩa
<code>remote_ratio</code>	2	1.52	0.2198	Không có ý nghĩa
<code>employment_type</code>	3	3.24	0.0218	Có ý nghĩa
<code>company_region</code>	2	97.18	< 1e-16	Có ý nghĩa
<code>cross_border</code>	1	16.25	6.34e-05	Có ý nghĩa
<code>work_year</code>	1	0.15	0.6949	Không có ý nghĩa
<code>experience_level:company_region</code>	6	1.40	0.2132	Không có ý nghĩa

So với bảng ANOVA cộng tính ban đầu (không có tương tác), các nhân tố chính giữ nguyên kết luận về ý nghĩa thống kê — thêm số hạng tương tác vào mô hình không làm đảo ngược vai trò của bất kỳ nhân tố nào đã xác định ở trên, chỉ bổ sung thêm một hàng cho `experience_level:company_region` với kết luận khớp với kiểm định F lồng nhau vừa trình bày.

Table 43: Lương trung bình theo từng ô experience_level x company_region

Kinh nghiệm	Khu vực	n	Lương trung bình	SD
Entry	Northern_America	34	\$ 89,938	\$47,273
Entry	Europe	32	\$ 46,515	\$24,719
Entry	Rest_of_World	22	\$ 39,919	\$40,155
Mid	Northern_America	98	\$116,593	\$55,777
Mid	Europe	84	\$ 63,572	\$28,580
Mid	Rest_of_World	26	\$ 39,362	\$34,924
Senior	Northern_America	196	\$148,840	\$49,988
Senior	Europe	34	\$ 88,433	\$34,728
Senior	Rest_of_World	13	\$ 84,635	\$69,642
Exec	Northern_America	18	\$204,750	\$60,455
Exec	Europe	7	\$127,159	\$56,001
Exec	Rest_of_World	1	\$ 79,039	\$ NA



Bảng và biểu đồ trên minh họa bản chất của tương tác: khoảng cách lương giữa Northern_America và Rest_of_World **không giống nhau** ở các cấp kinh nghiệm, cụ thể:

- **Exec:** Northern_America cao hơn Rest_of_World \$125,711/năm (\$204,750 so với \$79,039) — khoảng cách rộng nhất trong bốn cấp.
- **Senior:** chênh lệch còn \$64,205 (\$148,840 so với \$84,635).
- **Mid:** chênh lệch \$77,232 (\$116,593 so với \$39,362).
- **Entry:** chênh lệch chỉ còn \$50,019 (\$89,938 so với \$39,919) — hẹp nhất, khác biệt rõ rệt so với Exec.

Dù khoảng cách quan sát được không hoàn toàn đều nhau giữa các cấp kinh nghiệm, kiểm định F chính thức không đủ bằng chứng để khẳng định đây là một tương tác có ý nghĩa thống kê (thay vì biến động ngẫu nhiên do một số tổ hợp nhóm có cỡ mẫu nhỏ), nên mô hình cộng tính (`m_factorial`) vẫn được giữ làm mô hình suy diễn chính cho phần này.

2.5.3 Tóm tắt Phần Đánh giá và so sánh mô hình

Table 44: Tóm tắt Phần Đánh giá và so sánh mô hình

Mục	Kết_luận
Mô hình tốt nhất (RMSE thấp nhất)	3. Ridge
Hiệu năng trên tập kiểm định	RMSE $\approx$ \$45,742; MAE $\approx$ \$35,109; $R^2 \approx 0.431$
Biến quan trọng nhất	company_region và experience_level (nhất quán với EDA và Welch ANOVA/ANOVA Type II)
Biến ít quan trọng nhất	remote_ratioFullRemote, company_sizeMedium, work_year (nhất quán với LASSO và ANOVA Type II)
Phát hiện đáng chú ý	Ridge/LASSO chỉ cải thiện nhẹ so với OLS; OLS rút gọn (stepwise AIC) gần như không đổi so với OLS đầy đủ; biến đổi thang đo biến mục tiêu (log, Box–Cox) được khám phá thêm ở Phần Cải tiến mô hình như một hướng cải thiện khác

Ba phương pháp độc lập (ANOVA Type II, LASSO, hệ số chuẩn hoá Ridge) cùng kể một câu chuyện nhất quán: **experience_level**, **job_category** và **company_region** là **ba yếu tố ảnh hưởng mạnh và ổn định nhất đến mức lương**, trong khi **work_year** và phần lớn **remote_ratio** không đóng góp thêm. Phần Cải tiến mô hình sẽ kiểm tra sâu hơn độ tin cậy của mô hình được chọn và đề xuất hướng cải thiện.

2.6 Kiểm tra sâu hơn và đề xuất cải tiến mô hình

Mục tiêu. Kiểm chứng độ tin cậy của mô hình đã chọn bằng các phương pháp thay thế ít dựa vào giả định phân phối chuẩn — vì bảng BLUE đã ghi nhận 3/5 giả định bị vi phạm cho Mô hình 1 (RESET p 8.52e-05, Breusch–Pagan p 0.00304, Durbin–Watson p 0.0906, Shapiro–Wilk bác bỏ mạnh giả định chuẩn). Phần này đào sâu bằng năm nhóm phân tích bổ sung: quan trắc ảnh hưởng mạnh, độ nhạy hệ số qua hồi quy vững, kiểm định hoán vị, kích thước hiệu ứng, và biến đổi mục tiêu (log, Box–Cox) — rồi tổng hợp thành khuyến nghị cụ thể ở mục cuối.

Mô hình tham chiếu xuyên suốt phần này là một hồi quy trên **toàn bộ 565 quan sát** (khác với Phần Xây dựng mô hình dự đoán vốn chỉ ước lượng trên tập huấn luyện), loại **work_year** và **remote_ratio** — hai biến không có ý nghĩa thống kê trong bảng hệ số OLS ở Phần Xây dựng mô hình dự đoán (Mô hình 1) — để tập trung chẩn đoán sâu vào các yếu tố ảnh hưởng chính:

Shapiro–Wilk trên phần dư của mô hình này cho $W = 0.97$, $p = 2.29\text{e-}09$ (skewness 0.75) — xác nhận lại vi phạm chuẩn đã thấy ở Phần Xây dựng mô hình dự đoán, lần này trên toàn bộ dữ liệu thay vì chỉ tập huấn luyện. Đây là động lực cho các phương pháp thay thế ở phần này.

2.6.1 Quan trắc ảnh hưởng: Cook's distance

Mục tiêu. Xác định xem kết luận của mô hình tham chiếu có bị chi phối bởi một vài quan trắc đơn lẻ hay không — khác với kiểm định chuẩn phần dư (đánh giá hình dạng tổng thể), Cook's distance định vị **từng quan trắc cụ thể** có ảnh hưởng bất thường lên hệ số. Đây là thước đo chẩn đoán (không có H_0/H_1 hay p-value), dùng ngưỡng kinh nghiệm $4/n$ để khoanh vùng quan trắc cần xem xét thêm.



Table 45: 5 quan trắc có Cook's distance lớn nhất

	Cooks_D	salary_in_usd	experience_level	employment_type	job_category	company_region
78	0.1049	\$270,000	Mid	Contract	ML Engineer	Northern_America
283	0.0881	\$105,000	Senior	Contract	Data Scientist	Northern_America
487	0.0412	\$100,000	Entry	PartTime	Data Scientist	Rest_of_World
1	0.0400	\$260,000	Senior	FullTime	ML Engineer	Rest_of_World
488	0.0400	\$100,000	Mid	Freelance	Data Scientist	Northern_America

38/565 quan trắc vượt ngưỡng $4/n$, nhưng Cook's distance lớn nhất chỉ 0.105 — xa ngưỡng 1 thường dùng để cảnh báo một điểm chi phối toàn mô hình. Đáng chú ý hơn là **thành phần** của 5 quan trắc ảnh hưởng nhất: phần lớn thuộc `employment_type = Contract` ở mức lương cao — gợi ý hệ số `Contract` (dương, có ý nghĩa, $p \approx 0.067$) có thể không ổn định vì nhóm này chỉ có 5 quan sát. Mục tiếp theo kiểm tra trực tiếp bằng hai phương pháp độc lập.

2.6.2 Độ nhạy của hệ số với outlier: hồi quy vững và loại thử quan trắc ảnh hưởng

Mục tiêu. Cook's distance chỉ **định vị** quan trắc nghi ngờ, chưa cho biết loại bỏ chúng có thay đổi kết luận không. Hai phương pháp độc lập được chạy song song: (i) **hồi quy vững MM-estimation** (Yohai 1987, `robustbase::lmrob`) — giữ toàn bộ 565 quan sát nhưng tự động giảm trọng số các điểm có phần dư lớn; (ii) **loại thử 5 quan trắc** có Cook's distance lớn nhất rồi ước lượng lại OLS:

Table 46: Hệ số mô hình tham chiếu dưới ba cách ước lượng: OLS đầy đủ, hồi quy vững MM, và OLS sau khi loại 5 quan trắc Cook's D lớn nhất

	Biến	OLS (565 qs)	Robust MM	Loại top-5 Cook's D
(Intercept)	(Intercept)	72207	68476	72649
experience_levelMid	experience_levelMid	15237	14220	14316
experience_levelSenior	experience_levelSenior	45875	46022	44830
experience_levelExec	experience_levelExec	91023	91870	90170
employment_typePartTime	employment_typePartTime	-25241	-24523	-34217
employment_typeContract	employment_typeContract	36327	32113	33901
employment_typeFreelance	employment_typeFreelance	-50399	-45637	-64978
company_sizeMedium	company_sizeMedium	7105	8682	7885
company_sizeLarge	company_sizeLarge	14185	12033	14834
job_categoryData Engineer	job_categoryData Engineer	28053	29815	28061
job_categoryData Scientist	job_categoryData Scientist	31640	31114	31475
job_categoryML Engineer	job_categoryML Engineer	37388	31465	35391
job_categoryOther	job_categoryOther	55994	58189	55646
company_regionEurope	company_regionEurope	-58723	-54686	-58328
company_regionRest_of_World	company_regionRest_of_World	-71746	-71834	-75363
cross_border	cross_border	-25979	-23372	-25336


Cả hai phương pháp cho cùng bức tranh. Hệ số `employment_typeContract` **sụp đổ mạnh nhất**: giảm hơn 90% dưới ước lượng vững và đổi hẳn độ lớn khi loại 5 quan trắc ảnh hưởng — xác nhận hệ số dương của Contract trong OLS phần lớn do vài quan sát lương cao trong nhóm chỉ 5 quan sát chi phối, không phải hiệu ứng ổn định. Ngược lại, `experience_level`, `job_category`, `company_region` thay đổi rất ít ở cả hai cột; R^2 gần như không đổi (0.5351 $\rightarrow$ 0.5523). Có 0 quan trắc bị gán trọng số gần 0 (outlier cứng), gồm cả quan trắc lương cao nhất mẫu.

2.6.3 Kiểm định hoán vị (permutation test) cho `company_region`

Mục tiêu. Vì phần dư vi phạm giả định chuẩn, giá trị p của partial F-test lý thuyết cho `company_region` — nhân tố ảnh hưởng mạnh nhất theo cả ANOVA Type II lẫn Ridge — chỉ là xấp xỉ. Mục này kiểm định lại bằng phương pháp **không cần** giả định phân phối chuẩn: hoán vị ngẫu nhiên phần dư của mô hình không có `company_region`, cộng vào giá trị dự đoán để tạo dữ liệu giả lập dưới H_0 , rồi tính lại thống kê F trên mỗi bộ hoán vị. Cặp giả thuyết:

H_0 : sau khi đã kiểm soát `experience_level`, `employment_type`, `company_size`, `job_category`, `cross_border`, `company_size`

H_1 : `company_region` vẫn có hiệu ứng lên `salary_in_usd` sau khi đã kiểm soát các nhân tố trên (khu vực công ty vẫn ảnh hưởng)




Trong toàn bộ 2000 lần hoán vị, không lần nào tạo ra $F \geq F$ quan sát (113.73), cho $p_{\text{hoán vị}} \approx 5 \times 10^{-4}$ — cùng kết luận với partial F-test lý thuyết vừa tính ở trên (F 113.7, $p < 0.0001$), nhưng lần này **không phụ thuộc** vào giả định

phần dư có phân phối chuẩn. Kết quả củng cố rằng hiệu ứng `company_region` là một hiệu ứng thực sự trong dữ liệu, không phải hệ quả giả tạo từ việc vi phạm giả định.

2.6.4 Kích thước hiệu ứng (effect size) bên cạnh giá trị p

Mục tiêu. Partial F-test và permutation test chỉ cho biết một nhân tố có ý nghĩa thống kê hay không, chưa cho biết **độ lớn thực tế** — với cỡ mẫu 565, ngay cả hiệu ứng nhỏ cũng có thể đạt ý nghĩa. Mục này bổ sung góc nhìn độ lớn bằng η^2 riêng phần (partial eta-squared) — chỉ số mô tả (không có H0/H1) đo tỷ lệ biến động của `salary_in_usd` mỗi nhân tố giải thích được sau khi loại bỏ phần do các nhân tố khác:



`experience_level` ($\eta^2 \approx 0.38$) và `company_region` ($\eta^2 \approx 0.29$) là hai nhân tố duy nhất vượt ngưỡng “lớn” theo Cohen — nhất quán với hệ số chuẩn hoá Ridge và kiểm định hoán vị ở mục trên. `employment_type`, `company_size`, `job_category`, `cross_border` đều có ý nghĩa thống kê nhưng η^2 dưới 0.05 — có ý nghĩa nhưng đóng góp thực tế khiêm tốn.

2.6.5 Biến đổi mục tiêu: từ log đơn giản đến Box–Cox tối ưu

2.6.5.1 Mô hình bổ sung — OLS trên $\log(\text{salary_in_usd})$ **Mục tiêu.** Bảng BLUE xác nhận phần dư của Mô hình 1 vi phạm mạnh giả định chuẩn (Shapiro–Wilk). Hướng xử lý tiêu chuẩn là biến đổi log biến mục tiêu (Sheather 2009, §3.4) — trường hợp đặc biệt $\lambda = 0$ của Box–Cox. Mục này ước lượng log-OLS như mô hình bổ sung, kiểm tra xem biến đổi này có khắc phục vi phạm chuẩn và cải thiện dự đoán trên thang USD gốc hay không — trước khi tổng quát hoá bằng Box–Cox chính thức ở mục kế tiếp.

```
##
## Call:
## lm(formula = f_log, data = train_df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.50302 -0.23913  0.03524  0.28758  1.65472
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    0.068118   84.118846   0.001 0.999354
## work_year      0.005412    0.041626   0.130 0.896610
## experience_levelMid 0.180025    0.075416   2.387 0.017409 *
## experience_levelSenior 0.574145    0.078365  7.327 1.16e-12 ***
```

```
## experience_levelExec      0.896800    0.141557    6.335 5.92e-10 ***
## employment_typePartTime  -1.189547    0.202561   -5.873 8.53e-09 ***
## employment_typeContract    0.015143    0.261662    0.058 0.953876
## employment_typeFreelance  -0.702481    0.266587   -2.635 0.008712 **
## company_sizeMedium         0.059104    0.081928    0.721 0.471043
## company_sizeLarge         0.188935    0.078828    2.397 0.016960 *
## remote_ratioHybrid        -0.028974    0.086733   -0.334 0.738493
## remote_ratioFullRemote     0.010855    0.062560    0.174 0.862328
## job_categoryData Engineer  0.267714    0.071847    3.726 0.000220 ***
## job_categoryData Scientist 0.301177    0.069088    4.359 1.63e-05 ***
## job_categoryML Engineer    0.424227    0.086102    4.927 1.19e-06 ***
## job_categoryOther          0.342482    0.304973    1.123 0.262061
## company_regionEurope      -0.582318    0.063368   -9.189 < 2e-16 ***
## company_regionRest_of_World -1.183034    0.086788  -13.631 < 2e-16 ***
## cross_border              -0.350718    0.090217   -3.887 0.000117 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.5112 on 435 degrees of freedom
## Multiple R-squared:  0.5909, Adjusted R-squared:  0.574
## F-statistic: 34.9 on 18 and 435 DF, p-value: < 2.2e-16
```

Trên thang log, hệ số β của biến giả diễn giải thành **phần trăm chênh lệch**: $100(e^\beta - 1)\%$. **Senior** cao hơn Entry khoảng 77.6%, **Exec** cao hơn khoảng 145.2%; **Europe** thấp hơn Bắc Mỹ khoảng 44.1%, **Rest_of_World** thấp hơn khoảng 69.4%; làm việc xuyên biên giới gắn với mức giảm khoảng 29.6%. Cách diễn giải theo tỷ lệ này tự nhiên hơn với dữ liệu lương, vì mức tăng lương thường được thỏa thuận theo phần trăm.

Khi quy đổi dự đoán từ thang log về thang gốc, dùng $\exp(\hat{y})$ đơn thuần sẽ **chệch xuống một cách hệ thống** vì $E[\exp(\hat{y})] \neq \exp(E[\hat{y}])$ khi phần dư không chuẩn; mô hình áp dụng hệ số hiệu chỉnh **Duan smearing** (Duan 1983) — trung bình của $\exp(\text{phần dư})$ trên tập huấn luyện, ở đây bằng 1.1231.

Kiểm định lại BLUE trên thang log — biến đổi log có thực sự khắc phục vi phạm không? Cùng bốn kiểm định giả thuyết đã dùng cho Mô hình 1 ở Phần Xây dựng mô hình dự đoán (RESET, Breusch–Pagan, Durbin–Watson, Shapiro–Wilk — cặp H_0/H_1 như đã nêu ở mục BLUE tương ứng) được chạy lại trên `m_log`:

Table 47: Đối chiếu bốn giả định BLUE giữa Mô hình 1 (OLS thang gốc) và mô hình log-OLS (thang log)

Giả định	Mô hình 1 (gốc)	Log-OLS (log)
Tuyến tính (RESET)	Vi phạm	Vi phạm
Phương sai đồng nhất (Breusch–Pagan)	Vi phạm	Vi phạm
Không tự tương quan (Durbin–Watson)	Không vi phạm	Vi phạm
Chuẩn phần dư (Shapiro–Wilk)	Vi phạm	Vi phạm

Shapiro–Wilk trên `m_log` cho $W = 0.94$, $p = 1.39e-12$. So 3/4 giả định vi phạm ở Mô hình 1 với 4/4 ở mô hình log: biến đổi log làm số giả định vi phạm tăng lên — cần diễn giải thận trọng.

Table 48: Mô hình log-OLS so với 4 mô hình đã có ở Phần Đánh giá và so sánh mô hình, trên cùng tập kiểm định

Model	RMSE	MAE	R2
3. Ridge	\$45,742	\$35,109	0.4311
2. OLS rút gọn (stepwise AIC)	\$45,800	\$34,904	0.4297
1. OLS	\$46,047	\$35,279	0.4235
4. LASSO	\$46,071	\$35,170	0.4229
Log-OLS (smearing)	\$46,539	\$35,235	0.4111


Mô hình log-OLS xếp hạng 5/5 theo RMSE trên tập kiểm định — tệ nhất trong 5 mô hình đã xây dựng, dù đã cải thiện -1 giả định BLUE bị vi phạm so với Mô hình 1 (giả định chuẩn phần dư vẫn bị bác bỏ). Tốt hơn về giả định phân phối **không đồng nghĩa** tốt hơn về độ chính xác dự đoán: quy đổi ngược từ log khuếch đại sai số ở nhóm lương cao. Câu hỏi mục kế tiếp: liệu log ($\lambda = 0$) có phải mức biến đổi *đúng*, hay đã “biến đổi quá tay”?

2.6.5.2 Tìm λ tối ưu bằng kiểm định Box–Cox chính thức **Mục tiêu.** Mục trên cho thấy biến đổi log — phép biến đổi Box–Cox ứng với $\lambda = 0$ — tuy cải thiện một phần giả định BLUE nhưng không cải thiện (thậm chí có thể làm xấu đi) RMSE trên thang gốc so với OLS không biến đổi. Mục này tổng quát hoá bằng kiểm định Box–Cox chính thức, tìm λ tối ưu về log-likelihood thay vì chỉ thử hai lựa chọn cực đoan (không biến đổi $\lambda = 1$ và log $\lambda = 0$) như ở trên. Với mỗi giá trị λ_0 cần kiểm tra, cặp giả thuyết là:

$H_0 : \lambda = \lambda_0$ (mức biến đổi Box–Cox đúng bằng λ_0 ; hai trường hợp quan tâm nhất: $\lambda_0 = 1$ là không cần biến đổi, $\lambda_0 = 0$ là log)

$H_1 : \lambda \neq \lambda_0$ (mức biến đổi phù hợp khác λ_0)

và khoảng tin cậy xấp xỉ 95% cho $\hat{\lambda}$ (dựa trên kiểm định tỷ số hợp lý — likelihood-ratio test, ngưỡng $\chi^2_{1,0.95}$) chính là tập hợp mọi λ_0 **không bị bác bỏ**; hai trường hợp riêng quan tâm nhất là $\lambda_0 = 1$ (không cần biến đổi) và $\lambda_0 = 0$ (log) — nếu khoảng tin cậy không chứa một giá trị nào đó, H_0 tương ứng bị bác bỏ ở $\alpha = 0.05$:



$\hat{\lambda} \approx 0.48$, khoảng tin cậy 95% là $[0.41; 0.56]$ — không chứa cả $\lambda = 1$ lẫn $\lambda = 0$, nên cả hai H_0 (không biến đổi, hoặc log) đều **bác bỏ** ở $\alpha = 0.05$. Box–Cox xác nhận cần biến đổi, nhưng mức phù hợp nhẹ hơn log toàn phần — gần một phép lũy thừa trung gian giữa căn bậc hai và log. Đây là lý do log “biến đổi quá tay”, khớp với việc log làm RMSE thang gốc xấu đi.

Để kiểm chứng bằng số liệu dự đoán thực tế (không chỉ log-likelihood lý thuyết), mô hình được ước lượng lại trên thang $\lambda \approx 0.48$, huấn luyện/kiểm định trên đúng `train_df/test_df` đã chia ở Phần Xây dựng mô hình dự đoán, và quy đổi ngược bằng phép hiệu chỉnh kiểu smearing tổng quát (trung bình hoá qua toàn bộ phần dư huấn luyện, tương tự cách hiệu chỉnh Duan đã dùng cho log ở mục trên, nhưng áp dụng cho hàm ngược Box–Cox thay vì $\exp(\cdot)$):

Table 49: Mô hình Box-Cox (lambda tối ưu) so với mô hình log-OLS (mục trên) và 4 mô hình đã có ở Phần Đánh giá và so sánh mô hình, trên cùng tập kiểm định

Model	RMSE	MAE	R2
Box-Cox (lambda = 0.48)	\$44,767	\$33,964	0.4551
3. Ridge	\$45,742	\$35,109	0.4311
2. OLS rút gọn (stepwise AIC)	\$45,800	\$34,904	0.4297
1. OLS	\$46,047	\$35,279	0.4235
4. LASSO	\$46,071	\$35,170	0.4229
Log-OLS (smearing)	\$46,539	\$35,235	0.4111

Mô hình Box–Cox với λ tối ưu **vượt qua cả Ridge** (mô hình tốt nhất trước đó) lẫn log-OLS, ở cả ba chỉ số RMSE, MAE, R^2 , dù chỉ dùng OLS thuần túy trên thang đo đã biến đổi đúng mức. Phát hiện quan trọng nhất của Phần Cải tiến mô hình: **hướng cải tiến hiệu quả nhất không phải thuật toán phức tạp hơn (Ridge/LASSO), mà là biến đổi đúng thang đo biến mục tiêu trước khi hồi quy**. Khuyến nghị: **mô hình Box–Cox ($\lambda \approx 0.48$) nên là mô hình dự đoán được đề xuất**, thay thế Ridge.

2.6.6 Thử nghiệm mô hình Gradient Boosting: XGBoost và CatBoost

Mục tiêu. Toàn bộ các mô hình ở Phần Xây dựng mô hình dự đoán và ở trên đều là mô hình **tuyến tính** (OLS, Ridge, LASSO, log-OLS, Box–Cox) — giả định quan hệ cộng tính giữa các biến dự báo và (một phép biến đổi của) `salary_in_usd`. Theo Shwartz-Ziv & Armon (2021), các mô hình **Gradient Boosted Trees** thường đạt hiệu năng dự báo cao nhất trên dữ liệu dạng bảng (tabular data), đặc biệt khi tồn tại nhiều biến phân loại và quan hệ phi tuyến/tương tác giữa các biến — đúng đặc điểm của bộ dữ liệu này (6/8 biến dự báo là phân loại, và mục Tương tác ở Phần Đánh giá và so sánh mô hình đã xác nhận có tương tác giữa `experience_level` và `company_region`, điều mà một mô hình cộng tính thuần túy không nắm bắt được nếu không khai báo tường minh số hạng tương tác). Mục này thử nghiệm hai mô hình bổ sung, huấn luyện trên đúng `train_df/test_df` đã chia ở Phần Xây dựng mô hình dự đoán để so sánh công bằng:

- **XGBoost** (Chen & Guestrin 2016): huấn luyện trên ma trận thiết kế one-hot `x_train/x_test` đã dùng cho Ridge/LASSO.
- **CatBoost** (Prokhorenkova et al. 2018): xử lý trực tiếp các biến phân loại dạng gốc (không one-hot) bằng thuật toán **ordered target statistics**, tránh rủi ro rò rỉ thông tin (target leakage) khi mã hoá biến phân loại nhiều mức — phù hợp với đặc điểm phần lớn biến dự báo trong bộ dữ liệu là phân loại (`job_category`, `experience_level`, `company_size`, `employment_type`, `remote_ratio`, `company_region`).

Cả hai package `xgboost` và `catboost` đều đã sẵn có trong môi trường chạy báo cáo này.

2.6.6.1 XGBoost Thay vì cố định thủ công, siêu tham số được **tinh chỉnh bằng lưới (grid search)** kết hợp 5-fold cross-validation trên tập huấn luyện: lưới gồm `max_depth` (độ sâu cây), `eta` (tốc độ học) và `min_child_weight` (số quan sát tối thiểu mỗi lá — kiểm soát overfitting khi cỡ mẫu nhỏ); `subsample/colsample_bytree` giữ cố định ở 0.8 để giới hạn kích thước lưới. Với mỗi tổ hợp, số vòng lặp (`nrounds`) tối ưu được xác định bằng **early stopping** (`early_stopping_rounds` = 30) ngay trong CV, tránh overfitting mà không cần dò thêm một chiều riêng cho `nrounds`.

Table 50: 8 tổ hợp siêu tham số XGBoost có RMSE trung bình 5-fold CV thấp nhất

max_depth	eta	min_child_weight	nrounds tốt nhất	RMSE CV
3	0.10	5	62	\$44,155
3	0.05	5	116	\$44,427
3	0.03	5	200	\$44,473
3	0.10	1	64	\$44,644
3	0.05	1	99	\$44,696
6	0.03	5	134	\$44,728
3	0.03	1	199	\$44,741
6	0.05	5	81	\$44,753

Tổ hợp tốt nhất theo CV: max_depth = 3, eta = 0.1, min_child_weight = 5, với 62/800 vòng lặp (dừng sớm khi không cải thiện sau 30 vòng), RMSE CV = \$44,155. Mô hình cuối cùng được huấn luyện lại trên toàn bộ tập huấn luyện với tổ hợp này.

2.6.6.2 CatBoost Khác biệt cốt lõi so với XGBoost nằm ở cách xử lý biến phân loại: các cột phân loại trong train_df/test_df đã ở dạng factor sẵn từ bước tiền xử lý (Phần Tiền xử lý dữ liệu), nên catboost.load_pool() tự động nhận diện chúng làm categorical feature dựa trên kiểu cột của data.frame — không cần mã hoá one-hot như XGBoost/Ridge/LASSO, và cũng không cần khai báo tường minh chỉ số cột (cat_features), vì tham số này chỉ có tác dụng khi dữ liệu đầu vào là ma trận số thuần túy.

Theo đúng cách tiếp cận của CatBoost — không dùng trực tiếp tập kiểm định cuối cùng để chọn siêu tham số — tập huấn luyện train_df được chia tiếp thành tập xây dựng mô hình (fit, 80%) và tập validation (20%) để theo dõi RMSE và dừng sớm (early stopping):


Lưới tinh chỉnh gồm depth, learning_rate và l2_leaf_reg (điều chuẩn L2); với mỗi tổ hợp, mô hình được huấn luyện trên tập fit với tối đa 2.000 cây và early stopping trên tập validation (od_wait = 100, use_best_model = TRUE) để chọn số cây phù hợp, tương tự cơ chế đã dùng ở ví dụ CatBoost tham khảo:

Table 51: 8 tổ hợp siêu tham số CatBoost có RMSE validation thấp nhất

depth	learning_rate	l2_leaf_reg	Số cây tốt nhất	RMSE validation
6	0.10	3	42	\$48,641
6	0.10	10	122	\$49,090
6	0.10	5	54	\$49,347
8	0.10	10	48	\$49,416
4	0.10	3	34	\$49,422
4	0.05	10	104	\$49,436
4	0.10	10	114	\$49,476
4	0.10	5	41	\$49,540

Tổ hợp tốt nhất theo validation: depth = 6, learning_rate = 0.1, l2_leaf_reg = 3, với 42/2.000 cây (dừng sớm khi không cải thiện sau 100 vòng), RMSE validation = \$48,641. Mô hình cuối cùng được huấn luyện lại trên toàn bộ tập huấn luyện với tổ hợp này (không dùng early stopping ở bước huấn luyện lại).

2.6.6.3 Chẩn đoán dự đoán: Predicted vs Actual và phần dư Mục tiêu. Bảng RMSE/MAE/ R^2 ở mục tiếp theo tóm tắt sai số bằng một con số duy nhất, nhưng có thể che giấu các dạng lệch hệ thống (ví dụ mô hình luôn dự đoán thấp ở nhóm lương cao). Hai biểu đồ dưới đây kiểm tra trực quan: (i) lương dự đoán bám sát lương thực tế đến đâu, và (ii) phần dư có phân bố ngẫu nhiên quanh 0 hay lệch theo một quy luật nào đó.



Ở biểu đồ Predicted vs Actual, cả hai mô hình đều lệch có hệ thống theo hai chiều ngược nhau tùy nhóm lương: trong nhóm 25% lương thực tế **cao nhất**, phần lớn điểm nằm dưới đường chéo — mô hình **dự đoán thấp hơn thực tế** trung bình \$48,035 (XGBoost) và \$49,671 (CatBoost); ngược lại, ở nhóm 25% lương thực tế **thấp nhất**, mô hình lại **dự đoán cao hơn thực tế** trung bình \$25,571 (XGBoost) và \$28,792 (CatBoost) — cả hai mô hình đều có xu hướng “co” dự đoán về gần giá trị trung bình (shrinkage), một hạn chế điển hình khi biến mục tiêu lệch phải mạnh mà không mô hình cây nào trong số đã thử khắc phục triệt để, khớp với hạn chế tương tự đã ghi nhận ở các mô hình tuyến tính (Phần Xây dựng mô hình dự đoán).

Biểu đồ phần dư theo giá trị dự đoán cho thấy cùng hiện tượng dưới góc nhìn khác: tương quan giữa phần dư và giá trị dự đoán âm ở cả hai mô hình (XGBoost $r \approx -0.1$; CatBoost $r \approx -0.07$) — phần dư có xu hướng giảm dần khi giá trị dự đoán tăng, thay vì phân tán ngẫu nhiên quanh 0 như kỳ vọng ở một mô hình không thiên lệch.

Table 52: So sánh XGBoost, CatBoost và Box-Cox với các mô hình tuyến tính đã có, trên cùng tập kiểm định

Hạng	Mô hình	RMSE	MAE	R ² (test)
1	7. Box-Cox ($\lambda = 0.48$)	\$44,767	\$33,964	0.4551
2	5. XGBoost	\$45,344	\$34,326	0.4410
3	3. Ridge	\$45,742	\$35,109	0.4311
4	2. OLS rút gọn (stepwise AIC)	\$45,800	\$34,904	0.4297
5	1. OLS	\$46,047	\$35,279	0.4235
6	6. CatBoost	\$46,050	\$34,350	0.4234
7	4. LASSO	\$46,071	\$35,170	0.4229

2.6.6.4 So sánh với các mô hình đã có XGBoost (RMSE \$45,344) cải thiện so với 3. Ridge (RMSE \$45,742) nhưng chưa vượt qua mô hình Box-Cox — cỡ mẫu 565 quan sát có thể chưa đủ lớn để boosting phát huy hết lợi thế so với một mô hình tuyến tính đã biến đổi đúng thang đo.

CatBoost xếp hạng 6/7 với RMSE \$46,050 — không cải thiện thêm so với XGBoost trên bộ dữ liệu này, dù về lý thuyết ordered target statistics thường có lợi thế rõ hơn với biến phân loại có rất nhiều mức (high cardinality) — không phải trường hợp ở đây, vì job_category và company_region đã được gom về lần lượt 5 và 3 nhóm..

Dù không nhất thiết vượt trội hơn mô hình tuyến tính tốt nhất, thử nghiệm Gradient Boosting củng cố hai điểm đã nêu xuyên suốt báo cáo: (i) experience_level và company_region — bao gồm cả tương tác giữa hai biến này — là các yếu tố chi phối chính, được cả mô hình tuyến tính lẫn mô hình cây đồng thuận; (ii) với cỡ mẫu vừa phải (565 quan sát) và số biến dự báo không quá lớn, độ phức tạp bổ sung của Gradient Boosting không luôn chuyển hoá thành cải thiện dự đoán tương xứng — biến đổi đúng thang đo biến mục tiêu (Box-Cox) vẫn là hướng cải tiến hiệu quả nhất cho bộ dữ liệu này.

2.6.7 Tổng hợp và khuyến nghị mở rộng

Mục tiêu. Tổng hợp lại các phát hiện của bốn mục kiểm tra ở trên thành một bảng đối chiếu hạn chế – phân tích bổ sung, rồi nêu các hướng cải tiến cụ thể còn lại.

Table 53: Tổng hợp hạn chế phát hiện được và các phân tích bổ sung đã thực hiện ở Phần Cải tiến mô hình

Hạn_chế_phát_hiện	Phân_tích_bổ_sung_đã_thực_hiện
Phân dư vi phạm chuẩn (Shapiro-Wilk $p < 0.001$, xác nhận lại ở đầu Phần Cải tiến mô hình); log toàn phần không cải thiện RMSE (mục Biến đổi mục tiêu ở trên)	Thử log-OLS ($\lambda=0$) rồi kiểm định Box–Cox chính thức $\rightarrow$ λ tối ưu ≈ 0.4 , cải thiện RMSE hơn cả log-OLS lần 4 mô hình ở Phần Đánh giá và so sánh mô hình
Hệ số <code>employment_typeContract</code> không ổn định — do cỡ mẫu quá nhỏ ($n=5$)	Hồi quy vững (MM) + phân tích độ nhạy (loại top-5 Cook's D) — cả hai độc lập xác nhận
R^2 tối đa ~ 0.48 – 0.49 dù đã thử tới 7 mô hình khác nhau, kể cả Gradient Boosting (XGBoost/CatBoost)	Effect size (partial eta-squared) định lượng: chỉ <code>experience_level</code> , <code>company_region</code> đạt mức "lớn"
<code>work_year</code> mất ý nghĩa sau kiểm soát — xu hướng thời gian thô lẫn với thay đổi cơ cấu mẫu	Partial F-test lý thuyết + kiểm định hoán vị (cả hai ở mục Kiểm định hoán vị, Phần Cải tiến mô hình) cho cùng kết luận, không phụ thuộc giả định chuẩn
LASSO chỉ có từng dummy riêng lẻ, không loại nguyên khối <code>remote_ratio</code> dù cả khối không có ý nghĩa	Đã ghi nhận như hạn chế kỹ thuật của LASSO thường; grouped LASSO là hướng mở rộng

Các phân tích bổ sung đều **xác nhận lại**, chứ không đảo ngược, kết luận chính: `experience_level`, `job_category`, `company_region` là ba yếu tố ảnh hưởng thực sự và ổn định. Điểm mới phát hiện thêm: (i) hệ số `employment_type = Contract` không đáng tin cậy do cỡ mẫu quá nhỏ, và (ii) biến đổi Box–Cox đúng λ là hướng cải tiến dự đoán hiệu quả chưa được khai thác trước đó.

Ngoài các phân tích thực hiện được trực tiếp trên bộ dữ liệu hiện có, một số hướng cải thiện sau đòi hỏi thêm dữ liệu hoặc vượt phạm vi báo cáo này:

- **Thu thập thêm dữ liệu cho các nhóm nhỏ:** `employment_type` (PartTime/Contract/Freelance) và `job_category = Other` có cỡ mẫu dưới 20 — hệ số các nhóm này (đặc biệt Contract, đã xác nhận không ổn định) sẽ đáng tin cậy hơn với cỡ mẫu lớn hơn, thay vì phải dựa vào robust regression để “vá” vấn đề.
- **Biến bị bỏ sót:** R^2 tối đa (~ 0.49 , Box–Cox) cho thấy hơn một nửa biến động lương chưa được giải thích — có thể do kỹ năng chuyên môn cụ thể, tên công ty, hiệu suất cá nhân, hay kỹ năng thương lượng, không có trong dữ liệu gốc.
- **Grouped LASSO hoặc group SCAD:** chọn biến theo *cả khối* nhân tố phân loại (loại nguyên `remote_ratio` nếu không có ý nghĩa) thay vì từng dummy riêng lẻ như LASSO thường.
- **Hồi quy phân vị:** dữ liệu có đuôi lương cao dài và phương sai không đồng nhất theo `experience_level` — hồi quy phân vị mô tả cách các yếu tố ảnh hưởng khác nhau ở từng phân vị lương (ví dụ `company_region` ảnh hưởng mạnh hơn ở nhóm lương cao hay thấp), thay vì chỉ một hiệu ứng trung bình.
- **Dữ liệu nhiều năm hơn:** chỉ 3 năm (2020–2022) khiến `work_year` và cơ cấu mẫu thay đổi đồng thời, không tách bạch được xu hướng thời gian thuần túy khỏi thay đổi thành phần mẫu; dữ liệu trải dài hơn (5–10 năm) sẽ cho kiểm định đáng tin cậy hơn.